CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI

1.1. Bối cảnh nghiên cứu

Trong kỷ nguyên công nghệ số và Cách mạng công nghiệp 4.0, hình ảnh kỹ thuật số đã vượt qua vai trò lưu trữ kỷ niệm đơn thuần và trở thành phương tiện chủ đạo trong việc truyền tải thông tin và dữ liệu. Sự bùng nổ của các thiết bị di động thông minh tích hợp camera có độ phân giải cao, cùng với sự phát triển mạnh mẽ của các nền tảng mạng xã hội như Facebook, Instagram hay TikTok,... đã dẫn đến việc hàng tỷ bức ảnh được tạo ra và chia sẻ mỗi ngày trên toàn cầu. Hình ảnh hiện nay đóng vai trò không chỉ là dữ liệu thị giác mà còn là bằng chứng quan trọng trong các lĩnh vực thiết yếu như báo chí, truyền thông, chẩn đoán y tế, và đặc biệt là trong an ninh, điều tra tội phạm và pháp lý (Muley S. R., 2024).

Tuy nhiên, đi kèm với sự phổ biến này là một thách thức lớn đối với người dùng về tính toàn vẹn của dữ liệu khi các phần mềm chỉnh sửa hình ảnh chuyên nghiệp và các công cụ được hỗ trợ bởi trí tuệ nhân tạo ra đời và phát triển mạnh mẽ, các thao tác chỉnh sửa ảnh, cắt ghép làm giả thông tin trở nên dễ dàng hơn bao giờ hết. Các kỹ thuật giả mạo phổ biến như: Sao chép vùng (Copy – move), Cắt dán(Splicing), xóa – vẽ lại vật thể (impainting) hay Tạo ảnh bằng AI (AI generated),... ngày càng tinh vi, điều đáng báo động là rào cản kỹ thuật để thực hiện các hành vi này ngày càng thấp. Những hình ảnh này có thể được tạo ra bởi những người không có chuyên môn sâu, nhưng độ chân thực lại cao đến mức mắt thường khó có thể phân biệt đâu là ảnh gốc, đâu là ảnh đã qua chỉnh sửa.

Trong sự kiện bầu cử Tổng thống Mỹ năm 2004[1], một bức ảnh sử dụng kỹ thuật Splicing được lan truyền nhằm bôi nhọ chính trị. Trong bức ảnh này, ứng cử viên tổng thống John Kerry bị ghép đang ngồi cũng với nữ diễn viên theo chủ nghĩa hòa bình Jane Fonda. Vào thời điểm đó, Jane Fonda bị nhiều cử tri xem là một nhân vật thiếu tinh thần yêu nước. Việc bức ảnh này bị lan truyền có khả năng gây ảnh hưởng nghiêm trọng đến cục diện của chiến dịch tranh cử.

Tháng 3/2024[2], Điện Kensington công bố bức ảnh Vương phi Kate Middleton chụp cùng 3 người con nhân Ngày của Mẹ nhằm trấn an dư luận sau ca phẫu thuật của cô. Tuy nhiên, các chuyên gia nhiếp ảnh và cộng đồng mạng nhanh chóng soi ra một vài chi tiết bị biến dạng: tay áo của Công chúa Charlotte, khóa kéo áo khoác, hoa văn mờ nhòe... Hậu quả là 5 hãng thông tấn lớn nhất thế giới bao gồm AP, Reuters, Getty Images, AFP đã đồng loạt phát "lệnh gỡ bỏ" (kill notice) đối với bức ảnh này vì vi phạm tiêu chuẩn cốt lõi của báo chí về thao túng hình ảnh. Sự việc không chỉ

[1] Link sự kiện của John Kerry:
https://en.wikipedia.org/wiki/Kerry%E2%80%93Fonda_2004_election_photo_controversy

[2] Link sự kiện của Vương phi Kate Middleton:
https://time.com/6899993/princess-kate-middleton-photo-forensics-digital-provenance-credentials/

giáng đòn mạnh vào uy tín truyền thông của Hoàng gia Anh mà còn thổi bùng hàng loạt thuyết âm mưu vượt tầm kiểm soát trên toàn cầu.

Hay trong một vụ việc khác, một bức ảnh bị chỉnh sửa bằng Photoshop ác ý đã biến một người bình thường thành nghi phạm khủng bố toàn cầu, đe dọa trực tiếp đến tính mạng. Sau vụ tấn công khủng bố đẫm máu tại Paris năm 2015, một bức ảnh chụp một người đàn ông mặc áo đánh bom tự sát và cầm cuốn kinh Quran xuất hiện lan tràn trên mạng xã hội với cáo buộc đây là thủ phạm[3]. Nhưng thực tế, Bức ảnh gốc là của Veerender Jubbal, một nhà văn người Canada, đang cầm chiếc iPad để chụp ảnh tự sướng trước gương trong nhà tắm. Những kẻ ác ý đã dùng Photoshop biến chiếc iPad thành kinh Quran và vẽ thêm chiếc áo gắn bom. Bức ảnh giả mạo này bị tờ báo lớn La Razón của Tây Ban Nha và nhiều kênh truyền hình đưa lên trang nhất. Dù sau đó được minh oan, Veerender Jubbal đã phải hứng chịu làn sóng dọa giết, quấy rối khủng khiếp, khiến cuộc sống của anh bị hủy hoại và rơi vào khủng hoảng tâm lý nghiêm trọng.



Hình 1: Các bê bối do thao túng hình ảnh tiêu biểu trên thế giới và hệ quả thực tế nêu trên: Ghép ảnh bôi nhọ chính trị (trên bên trái), chỉnh sửa chi tiết gây mất lòng tin truyền thông (trên bên phải) và Photoshop ác ý hủy hoại danh dự cá nhân (phía dưới).

Hệ quả của vấn nạn này là vô cùng nghiêm trọng: việc lan truyền các hình ảnh đã bị chỉnh sửa không chỉ dừng lại ở việc phát tán tin giả gây hoang mang dư luận, làm

[3] Link sự kiện của Veerender Jubbal: https://www.cbc.ca/news/trending/paris-attacks-canadian-sikh-selfie-photoshop-1.3320327

xói mòn niềm tin trong cộng đồng, mà còn tiềm ẩn rủi ro lớn về an ninh quốc gia, sai lệch kết quả bầu cử chính trị và làm giả bằng chứng trước tòa án. Do đó, nhu cầu xây dựng các mô hình phát hiện hình ảnh bị chỉnh sửa với độ tin cậy cao nhằm bảo vệ tính xác thực của thông tin trong không gian số đang trở nên cấp thiết hơn bao giờ hết.

1.2. Lịch sử giải quyết vấn đề:

Lịch sử nghiên cứu về bài toán phát hiện ảnh giả mạo đã có từ lâu đời và liên tục phát triển song hành cùng với sự tiến bộ của công nghệ kỹ thuật số. Nhằm đối phó với các thủ đoạn thao túng hình ảnh ngày càng tinh vi, đã có rất nhiều phương pháp nghiên cứu được đề xuất để đánh giá tính xác thực của một bức ảnh thậm chí xác định vị trí các khu vực bị chỉnh sửa. Thông qua quá trình khảo sát các công trình nghiên cứu hiện có, các phương pháp tiêu biểu có thể được phân chia thành các nhóm chính như sau:

1.2.1. Phương pháp phát hiện dựa trên điểm đặc trưng (Keypoint)

Nghiên cứu của Amerini et al. (2011) là một trong những nghiên cứu dựa trên điểm đặc trưng được trích dẫn nhiều nhất. Nhóm tác giả sử dụng thuật toán SIFT (Scale Invariant Feature Transform) để phát hiện ảnh sao chép - dán. Nghiên cứu chứng minh rằng SIFT vô cùng mạnh mẽ trước các phép biến đổi xoay và thu phóng hình học, tuy nhiên sẽ gặp khó khăn khi vùng bị cắt ghép quá đồng nhất và trơn nhẵn.

Alberry et al. (2018) ứng dụng quy trình kết hợp SIFT và Fuzzy C-Means (FCM) để phân cụm các điểm so khớp dự kiến, giúp giảm khoảng 15% thời gian chạy tính toán mà vẫn duy trì chất lượng phát hiện tương đương các phương pháp SIFT truyền thống.

1.2.2. Phương pháp phát hiện dựa trên khối/mảng (Block/Patch)

Agarwal et al. (2019) đã đề xuất một mô hình học sâu để phát hiện kỹ thuật Copy – Move, bắt đầu bằng việc phân đoạn hình ảnh dựa trên tính tương đồng màu sắc thông qua thuật toán SLIC. Để đảm bảo tính bền vững trước các phép biến đổi hình học như xoay hay co giãn, nhóm tác giả sử dụng mạng VGGNet nhằm trích xuất các đặc trưng đa tỷ lệ từ những phân đoạn đã xử lý. Các vùng bị làm giả sau đó được xác định thông qua cơ chế khớp mảnh thích ứng và tái tạo độ sâu pixel để so sánh sự trùng lặp giữa các khối nghi ngờ. Phương pháp này được đánh giá là có khả năng cải thiện đáng kể độ chính xác đồng thời giảm thiểu chi phí tính toán trong việc định vị khu vực giả mạo.

Mehjardi et al. (2026) đã đề xuất một mô hình lai mang tên HDBK nhằm gia tăng độ chính xác trong việc nhận diện và khoanh vùng hình ảnh bị chỉnh sửa bằng kĩ thuật Copy-Move. Thay vì sử dụng phương pháp dựa trên khối (block-based) thông thường, nhóm tác giả đã ứng dụng Generatic Algorithm. Thuật toán này giúp tìm kiếm nhanh và tối ưu ra các khối tương đồng với vùng nghi ngờ bị chỉnh sửa.

1.2.3. Phương pháp dựa trên dấu vết nén (Compression Artifacts)

Dua et al. (2020) đã trình bày một phương pháp dựa trên nén JPEG. Các hệ số DCT rời rạc được đánh giá độc lập cho mỗi khối của hình ảnh được phân chia thành các khối không chồng chéo có kích thước 8 × 8 pixel. Các đặc điểm thống kê của các thành phần AC của các hệ số DCT khối thay đổi khi hình ảnh nén JPEG bị giả mạo. SVM được sử dụng để phân loại hình ảnh thật và giả mạo bằng cách sử dụng vectơ đặc trưng được truy xuất.

Tương tự Khalil, Ali et al. (2022) đã đề xuất một phương pháp phát hiện ảnh giả mạo bằng cách sử dụng kỹ thuật nén lại hình ảnh (recompressing images) kết hợp với học sâu. Mô hình này tận dụng mạng nơ-ron để học các dấu vết đặc trưng để lại do sự không nhất quán khi một vùng ảnh bị dán vào và trải qua quá trình nén lại, từ đó nhận diện các khu vực đã bị thao túng một cách hiệu quả.

Hay trong nghiên cứu của Malick et al. (2022), nhóm tác giả đề xuất phương pháp sử dụng CNN để phát hiện hai kỹ thuật Copy – Move và Splicing thông qua ba giai đoạn: tiền xữ lí dữ liệu, chuyển đổi ảnh sang dạng ELA (Error Level Analysis) và sử dụng ELA cơ bản, VGG16, VGG19 để phân loại. Ưu điểm chính của phương pháp này là sử dụng ảnh đầu vào ELA giúp loại bỏ các thông tin dư thừa như màu sác, nhiễu,... Về hướng phát triển trong tương lai, các tác giả đề xuất mở rộng tập dữ liệu huấn luyện và sử dụng kiến trúc hệ thống có độ tính toán cao hơn để tăng cường độ chính xác cũng như khắc phục những hạn chế về tính tổng quát hóa trên các tập dữ liệu khác nhau.

Một nghiên cứu khác của Khalil et al. (2023) cũng dựa trên nguyên lí giả định rằng vùng ảnh bị chỉnh sửa có chất lượng nén khác so với các vùng khác trong ảnh. Điểm cốt lõi của nghiên cứu này là các tác giả sữ dụng kỹ thuật Học chuyển giao (Transfer Learning), tác giả sử dụng 8 pre-trained models bao gồm: VGG16, VGG19, ResNet50, ResNet101, ResNet152, MobileNetV2, Xception, và DenseNet. Hiệu suất của các mô hình Transfer Learning đều đạt độ chính xác cao hơn hẳn so với CNN thuần túy. Nhóm tác giả hướng đến vấn đề định vị cụ thể các vùng ảnh bị chỉnh sửa và tính tổng quát hóa trên đa dạng tập dữ liệu, các kỹ thuật chỉnh sửa ảnh khác. Ngoài ra, nghiên cứu còn nhắc đến việc cần tăng cường độ chính xác phát hiện giả mạo, đồng thời chú trọng giảm thiểu thời gian huấn luyện và chi phí tính toán.

Theo hướng tối ưu hóa tài nguyên tính toán, Chathampally et al. (2024) đã đề xuất một kiến trúc dựa trên MobileNetV2 kết hợp với kỹ thuật Học chuyển giao (Transfer Learning) để xác thực hình ảnh. Phương pháp của họ tích hợp bước Phân tích Lỗi Nén (Compression Error Analysis - CEA) ở khâu tiền xử lý, giúp làm nổi bật các dấu vết chỉnh sửa trước khi đưa vào mạng CNN. Việc sử dụng kiến trúc MobileNetV2 giúp mô hình phân loại chính xác hình ảnh thật và giả trên tập dữ liệu CASIA V2 mà vẫn duy trì được sự tối ưu về mặt khối lượng tính toán.

1.2.4. Phương pháp sử dụng Học sâu với kiến trúc phức tạp

Một phương pháp đề xuất khác phát hiện ảnh bị chỉnh sửa mà không phụ thuộc vào chất lượng của hình ảnh (Aria et al., 2022). Chiến lược của phương pháp này là sử dụng Generative Adversarial Networks (GANs) để nâng cao chất lượng của hình

ảnh và CNN với kiến trúc dual-branch, một nhánh để phát hiện thao tác nhằm tìm kiếm dấu vết chỉnh sửa và một nhánh tìm kiếm sự tương đồng để xác định vị trí bị chỉnh sửa. Phương pháp này có thể phát hiện đồng thời nhiều vùng giả mạo, phân biệt rõ vùng nguồn (source) và vùng mục tiêu (target), hoạt động tốt với cả vùng giả mạo nhỏ.

Trong một nghiên cứu khác, Qazi et al. (2022) đã sử dụng các kỹ thuật học sâu để phát hiện hình ảnh bị chính sửa một cách chính xác, trong đó ResNet50v2 được sử dụng làm mô hình nền tảng. Ngoài ra, họ đã sử dụng trọng số YOLO CNN cho việc Học chuyển giao. Kỹ thuật này đã tạo điều kiện thuận lợi cho việc huấn luyện mô hình bằng cách phân bổ trọng số đáng kể. Các tác giả đã sử dụng trọng số được huấn luyện trước từ mô hình phát hiện đối tượng YOLO CNN để khởi tạo kiến trúc được đề xuất của họ dựa trên ResNet50v2. Cách tiếp cận này đã giảm đáng kể chi phí trong quá trình huấn luyện. Mô hình được khởi tạo bằng cách sử dụng các trọng số có sẵn bao gồm thông tin có giá trị. Một lợi thế của cách tiếp cận này là nó làm giảm hiệu quả thời gian huấn luyện cần thiết bằng cách sử dụng kiến trúc dựa trên ResNet.

Cũng hướng đến việc khoanh vùng hình ảnh, Zhang et al. (2022) đã giới thiệu một mạng nơ-ron đối nghịch sinh (GAN) lai giữa kiến trúc CNN và Transformer (CNN-T GAN). Trong thiết kế của họ, bộ sinh (generator) bao gồm một nhánh CNN và một nhánh Transformer hoạt động song song để trích xuất cả đặc trưng cục bộ lẫn toàn cục. Mô hình này tỏ ra cực kỳ hiệu quả trong việc định vị vùng sao chép và đặc biệt là khả năng phân biệt chính xác đâu là vùng ảnh gốc (source) và đâu là vùng được dán (target) trong kỹ thuật Copy-Move.

Gần đây, Korsipati et al. (2025) đã giới thiệu một mô hình phân loại ảnh giả mạo mạnh mẽ dựa trên Học chuyển giao đa độ phân giải. Nhóm tác giả sử dụng mạng EfficientNetV2-B0 làm nền tảng, kết hợp với các khối Fused-MBConv được tăng cường bởi cơ chế chú ý Squeeze-and-Excitation (SE). Việc tinh chỉnh này, kết hợp cùng quá trình tối ưu hóa các lớp phân loại (CNN heads) bằng hàm mất mát Focal Loss, đã giúp hệ thống xử lý tốt vấn đề mất cân bằng dữ liệu và đạt hiệu suất vượt trội trên các tập dữ liệu chuẩn như CASIA v1.0 hay Columbia.

Tập trung vào bối cảnh môi trường mạng xã hội, Al-Nabhani et al. (2026) đã đề xuất REFORGE, một mô hình tập hợp (Robust Ensemble) kết hợp nhiều mạng học sâu nhằm phát hiện và định vị vùng ảnh bị giả mạo. Nghiên cứu này được thiết kế đặc biệt để giải quyết bài toán các bức ảnh bị nén và làm giảm chất lượng khi đăng tải lên các nền tảng trực tuyến, giúp hệ thống phát hiện duy trì tính bền vững (Robustness) cao trước các phép biến đổi ảnh phức tạp của mạng xã hội.

1.2.5. Các nghiên cứu khảo sát và tổng hợp

Ở một góc độ tổng quan, Ibrahim et al. (2025) đã thực hiện một nghiên cứu khảo sát chi tiết về các phương pháp học sâu, đặc biệt là mạng CNN, trong việc phát hiện giả mạo Copy-Move. Nghiên cứu tập trung phân tích các mô hình tiên tiến từ năm 2019 đến 2023, đồng thời tổng hợp các bộ dữ liệu phổ biến trong lĩnh vực pháp y hình ảnh. Nhóm tác giả cũng chỉ ra rằng việc áp dụng các kỹ thuật tập hợp (Ensemble

Techniques) để kết hợp nhiều phương pháp sẽ giúp cải thiện đáng kể hiệu suất phát hiện giả mạo tổng thể.

Muley el al. (2024) đã thực hiện một nghiên cứu chuyên sâu về các kỹ thuật phát hiện chỉnh sửa ảnh, so sánh giữa các phương pháp trích xuất đặc trưng truyền thống và các kỹ thuật Học sâu tiên tiến. Tác giả đã đề xuất một framework hệ thống gồm hai giai đoạn: Cơ chế xác thực ảnh và Cơ chế phát hiện giả mạo, nhằm cải thiện quá trình phân loại và định vị vùng bị thao túng một cách có hệ thống và bao quát.

Có thể thấy mỗi phương pháp đều tồn tại những hạn chế nhất định. Cụ thể, các phương pháp truyền thống (dựa trên Block, Patch hoặc Keypoint) thường chỉ hoạt động dựa trên cơ chế so khớp sự trùng lặp cục bộ, do đó chúng gần như chỉ phát hiện được duy nhất một kỹ thuật là Copy-Move mà hoàn toàn bất lực trước kỹ thuật Splicing, cắt ghép từ các nguồn ảnh khác nhau. Mặt khác, việc ứng dụng các mô hình học sâu có kiến trúc phức tạp như mạng GAN, mạng Ensemble, mạng nhánh kép... để tìm nhiều lỗi cùng lúc lại đòi hỏi tài nguyên tính toán khổng lồ. Thêm vào đó, việc để mạng CNN học trực tiếp từ ảnh màu RGB thông thường sẽ khiến mô hình dễ bị nhiễu bởi các thông tin ngữ nghĩa và màu sắc tự nhiên của bức ảnh.

Khác với cách tiếp cận tạo ra các mô hình hay nhánh (branch) rời rạc để xử lý từng loại giả mạo riêng biệt, luận văn này định hướng xây dựng một luồng xử lý thống nhất. Đề tài áp dụng kỹ thuật Phân tích mức độ lỗi (Error Level Analysis) ở bước tiền xử lý nhằm triệt tiêu nhiễu thị giác và làm nổi bật sự bất đồng nhất của dấu vết nén, kết hợp với các kiến trúc Học chuyển giao (Transfer Learning) gọn nhẹ nhưng mạnh mẽ. Điểm khác biệt cốt lõi là chứng minh hệ thống có khả năng phát hiện cả hai kỹ thuật giả mạo tinh vi là Copy-Move và Splicing thông qua một luồng phân loại duy nhất. Cách tiếp cận này vừa khắc phục được nhược điểm chỉ phát hiện một lỗi của các phương pháp thủ công, vừa giải quyết được bài toán tối ưu hóa tài nguyên so với các mạng học sâu đồ sộ.

1.3. Đặt vấn đề

Trong môi trường thực tế, một bức ảnh giả mạo được tạo ra để che mắt người xem thường là sản phẩm của nhiều thủ đoạn cắt ghép và sao chép phức tạp đan xen lẫn nhau. Việc các hệ thống pháp y số chỉ phụ thuộc vào những thuật toán đơn lẻ, chuyên biệt cho từng loại thao tác sẽ để lại những lỗ hổng an ninh lớn và thiếu tính linh hoạt. Một hệ thống phòng thủ và xác thực hình ảnh hiệu quả trong thời đại số bắt buộc phải có khả năng nhận diện đồng thời các kỹ thuật thao túng phổ biến nhất, tiêu biểu là Copy-Move và Splicing.

Mặc dù hướng tiếp cận kết hợp tiền xử lý bóc tách dấu vết nén hình ảnh và sức mạnh của Mạng nơ-ron tích chập (CNN) đã chứng minh được tiềm năng to lớn trong việc giải quyết bài toán này, nhưng một thách thức mới lại xuất hiện. Sự bùng nổ liên tục của hàng loạt kiến trúc mạng học sâu tiên tiến đặt ra một khoảng trống lớn trong khâu đánh giá. Khi đứng trước một cấu trúc dữ liệu đặc thù như bản đồ sai khác chất lượng nén, đâu mới thực sự là kiến trúc mạng mang lại hiệu năng phân loại tối ưu nhất, đồng thời đáp ứng được yêu cầu về tốc độ xử lý.

Để giải quyết trọn vẹn vấn đề đó, đề tài đặt ra yêu cầu phải thực hiện một quá trình nghiên cứu thực nghiệm và so sánh toàn diện. Cụ thể, đề tài lựa chọn triển khai năm kiến trúc Mạng nơ-ron tích chập bao gồm: mô hình Custom CNN tự thiết kế, VGG19, ResNet50, EfficientNet-B0 và MobileNetV2 kết hợp Transfer Learning. Việc đặt các kiến trúc mạng với đa dạng phương pháp thiết kế này lên cùng một hệ quy chiếu trên tập dữ liệu chuẩn hóa sẽ giúp tìm ra mô hình đạt sự cân bằng hoàn hảo nhất giữa độ chính xác và chi phí tài nguyên tính toán.

1.4. Mục tiêu nghiên cứu

Để tìm kiếm câu trả lời cho hai câu hỏi nghiên cứu trên, đề tài tập trung vào mục tiêu cụ thể như sau:

- Xây dựng và chuẩn hóa một quy trình phát hiện giả mạo thống nhất dựa trên Deep Learning. Quy trình này tập trung vào việc tiền xử lý dữ liệu để trích xuất đặc trưng chung, cho phép mô hình nhận diện đồng thời cả hai kỹ thuật chỉnh sửa phổ biến là Copy-move và Splicing mà không cần xây dựng các nhánh xử lý riêng biệt.
- Thực nghiệm, đánh giá và so sánh hiệu năng của các kiến trúc mạng dùng đã huấn luyện trên cùng một tập dữ liệu đã chuẩn hóa. Mục đích là xác định mô hình tối ưu nhất dựa trên sự đánh giá thông qua các chỉ số: độ Accuracy, F1-score và AUC. Việc kết hợp các chỉ số này nhằm đảm bảo mô hình không chỉ đạt hiệu suất phân loại cao mà còn duy trì được độ bền vững (Robustness) và tính ổn định trước các biến đổi phức tạp của dữ liệu hình ảnh đầu vào.

1.5. Phạm vi và giới hạn của đề tài

Khi tiếp cận luận văn này, việc thừa nhận phạm vi và các giới hạn của nó là vô cùng quan trọng. Điều này sẽ đảm bảo rằng các kết luận được rút ra đều dựa trên cơ sở vững chắc nằm trong giới hạn của nguồn lực và dữ liệu sẵn có. Phần này cũng cung cấp bối cảnh cho các hàm ý và ứng dụng tiềm năng từ những phát hiện của nghiên cứu.

1.5.1. Phạm vi đề tài

- Nghiên cứu giới hạn ở việc phát triển, đánh giá và so sánh các mô hình Deep Learning, cụ thể là năm kiến trúc Mạng nơ-ron tích chập: CNN tự thiết kế, VGG16, ResNet50, EfficientNet B0 và MobileNetV2, nhằm mục đích phân loại nhị phân gồm lớm Authentic (ảnh thật) – Tampered (ảnh bị chỉnh sửa) cho các hình ảnh bị can thiệp bởi kỹ thuật Copy-move (sao chép vùng) và Splicing (cắt ghép).
- Nghiên cứu sử dụng dữ liệu từ một bộ dữ liệu công khai là CASIA v2.0 và sẽ không tìm kiếm thêm bất kỳ dữ liệu bên ngoài nào khác trong quá trình thực nghiệm.

1.5.2. Giới hạn đề tài

Thứ nhất, nghiên cứu bị giới hạn bởi tính chất "phòng thí nghiệm" của dữ liệu. Do đó, nó có thể chứa các sai lệch bắt nguồn từ phương pháp thu thập dữ liệu ban đầu. Các mô hình có thể hoạt động tốt trên tập dữ liệu chuẩn nhưng hiệu năng có thể suy giảm khi đối mặt với các điều kiện phức tạp trong thực tế như: ảnh bị nén nhiều lần trên mạng xã hội, ảnh chụp màn hình... Vì vậy, kết quả có thể chưa hoàn toàn tổng quát hóa được cho mọi tình huống thực tế.

Thứ hai, luận văn tập trung vào việc đánh giá khả năng phân loại (classification) của các mô hình Deep Learning, bỏ qua việc khám phá khả năng định vị (localization) hoặc phân đoạn vùng bị chỉnh sửa (segmentation).

Cuối cùng, các nguồn lực tính toán sẵn có cho nghiên cứu này đặt ra một hạn chế về độ phức tạp và sự đa dạng của các thí nghiệm có thể được thực hiện, cũng như giới hạn phạm vi nghiên cứu không bao gồm các loại hình ảnh giả mạo mới nổi như Deepfake hay ảnh được tạo sinh bởi AI.

1.6. Cấu trúc luận văn

Luận văn được tổ chức thành 5 chương chính, mỗi chương trình bày một nội dung cụ thể nhằm làm rõ quá trình nghiên cứu và kết quả đạt được của đề tài.

Chương 1: Trình bày tổng quan về đề tài nghiên cứu, bao gồm bối cảnh, lịch sử nghiên cứu, vấn đề đặt ra, mục tiêu, phạm vi và giới hạn của đề tài. Đây là cơ sở để định hướng toàn bộ nội dung nghiên cứu trong luận văn.

Chương 2: Trình bày cơ sở lý thuyết liên quan đến đề tài, bao gồm: các khái niệm về hình ảnh bị chỉnh sửa, hai kỹ thuật chỉnh sửa được được lựa chọn đế phân tích trong nghiên cứu này (Copy-Move và Splicing), các phương pháp phát hiện ảnh giả mạo, giải thuật nén JPEG, kỹ thuật Error Level Analysis (ELA), cũng như các kiến trúc Mạng nơ-ron tích chập và phương pháp học chuyển giao (Transfer Learning) được sử dụng trong nghiên cứu.

Chương 3:Trình bày phương pháp thực hiện đề tài, mô tả chi tiết quy trình thu thập và tiền xử lý dữ liệu, cách xây dựng mô hình, chiến lược huấn luyện mô hình CNN và các mô hình Transfer Learning, cấu hình huấn luyện và các chỉ số đánh giá mô hình.

Chương 4: Trình bày kết quả của nghiên cứu. Nội dung chương này bao gồm kết quả huấn luyện của các mô hình, biểu đồ so sánh các chỉ số đánh giá của từng mô hình, bảng so sánh hiệu năng giữa các kiến trúc khác nhau và trả lời các câu hỏi nghiên cứu đã đặt ra.

Chương 5: Chương này tổng kết lại các kết quả đạt được của đề tài, đồng thời đề xuất các hướng nghiên cứu trong tương lai nhằm cải thiện và mở rộng hệ thống.

CHƯƠNG 2: CƠ SỞ LÍ THUYẾT

2.1. Thế nào là hình ảnh bị chỉnh sửa?

Ngày nay, trong thời đại công nghệ thông tin bùng nổ và sự phát triển mạnh mẽ của các nền tảng truyền thông, ý nghĩa của hình ảnh không còn dừng lại ở việc lưu giữ kỉ niệm đơn thuần mà đã trờ thành phương tiện giao tiếp truyền tải thông tin chủ đạo của xã hội. Hầu hết, các bài đăng trên mạng xã hội hay các bài báo truyền tải bất kì thông tin gì cũng đều có ít nhất một hình ảnh để dẫn chứng hay minh họa. Đặc biệt hơn, hình ảnh được công nhận là một nguồn bằng chứng quyết định, có giá trị xác thực cao trong lĩnh vực trọng yếu như chẩn đoán y tế, tình báo quân sự, điều tra tội phạm và các thủ tục pháp lí trước tòa.

Hình ảnh bị chỉnh sửa hay còn gọi là làm giả hoặc thao túng là những hình ảnh đã bi can thiệp một cách có chủ đích vào cấu trúc pixel hoặc nội dung gốc thông qua các phần mềm đồ họa như Photoshop, GIMP,... hoặc các công cụ tạo sinh hình ảnh bằng Trí tuệ nhân tạo. Mục đích của các hành vi này là che giấu, xóa bỏ hoặc thêm thắt các chi tiết nhằm bóp méo các thông tin thực tế. Sự nguy hiểm của hình ảnh bị chỉnh sửa nằm ở chỗ các công cụ hiện đại có khả năng tạo ra những sản phẩm giả mạo với độ chân thực cực kỳ cao, vượt qua khả năng nhận biết đối với mắt thường của con người. Việc phát tán các hình ảnh bị chỉnh sửa có thể dẫn đến việc lan truyền tin giả gây hoang mang dư luận, xói mòn niềm tin của cộng đồng, thay đổi cục diện của bằng chứng pháp lý và thậm chí đe dọa đến an ninh quốc gia.

2.2. Các kỹ thuật chỉnh sửa hình ảnh

Cùng với sự phát triển vượt bậc của các phần mềm chỉnh sửa hình ảnh là sự ra đời liên tục của các kĩ thuật chỉnh sửa hình ảnh. Trong nghiên cứu này, tôi tập trung vào hai kĩ thuật chính là Copy – Move và Splicing.

2.2.1. Copy – Move

Kỹ thuật này được thực hiện bằng cách sao chép một hoặc nhiều vùng của hình ảnh và dán chúng vào chính bức ảnh đó ở các vị trí khác nhau. Đặt điểm nhận diện cốt lõi của kĩ thuật này là bức ảnh sau khi chỉnh sửa không chứa bất kì chi tiết hình ảnh nào được lấy từ nguồn bên ngoài.

Mục đính chính của kĩ thuật này là nhằm che dấu, xóa bỏ một đối tượng hoặc thông tin quan trọng nào đó trong ảnh bằng cách sao chép cùng nền đè lên đối tượng. Ngoài ra, người chỉnh sửa còn có thể dùng Copy – Move để nhân bản vật thể hay con người nhằm làm tăng số lượng đối tượng thật sự có trong hình để phóng đại quy mô của mố của sự kiện.

Để mắt thường không thể nhận ra vùng bị dán ép, người chỉnh sửa hiếm khi chỉ thực hiện thao tác Copy – Move cơ bản. Thay vào đó, phần được dán thường bị can thiệp bởi các phép biến đổi hình học (như xoay, thay đổi tỷ lệ, thu phóng) và các phép toán hậu xử lý phức tạp (như làm mờ viền cạnh, thay đổi độ sáng, độ tương phản, giảm màu, thêm nhiễu hoặc nén JPEG).

Copy-Move được xem là kỹ thuật giả mạo tinh vi và rất khó bị phát hiện bằng các phương pháp kiểm tra thông thường do vùng được sao chép có cùng nguồn gốc với phần còn lại của bức ảnh, do đó chúng có sự đồng nhất hoàn hảo về các thuộc tính quang học cốt lõi như nhiệt độ màu, điều kiện ánh sáng phản chiếu, kết cấu và mức độ nhiễu của cảm biến



Hình 2: Ảnh minh họa kĩ thuật Copy-move

2.2.2. Splicing

Splicing là kĩ thuật cắt cắt một phần hay toàn bộ nội dung của một bức ảnh và dán vào một bức ảnh hoàn toàn khác nhằm tạo một tình huống giả hoặc tổng hợp thành một hình ảnh chưa từng tồn tại trên thực tế.

Kĩ thuật này thường được sử dụng để tạo ra các tình huống đánh lừa thị giác. Theo các chuyên gia pháp y số, đây là một hình thức thao giả mạo, thao túng mạnh tay và mang tính chất lừa dối cao.

Khác với Copy-Move, hình ảnh dùng để cắt ghép trong Splicing có nguồn gốc từ các ảnh gốc khác nhau, do đó chúng sẽ mang những thuộc tính thị giác khác biệt rõ rệt về nhiệt độ màu, điều kiện chiếu sáng (hướng bóng đổ, độ sáng) và các mức nhiễu cảm biến. Để hợp nhất các vùng ghép này vào bức ảnh mục tiêu sao cho trông thật tự nhiên, người giả mạo bắt buộc phải thực hiện các bước hậu xử lý như thay đổi kích thước, cắt cúp, xoay, cân bằng biểu đồ histogram, cũng như áp dụng bộ lọc trung bình để làm mịn ranh giới giữa các vùng ghép.

Việc chèn thêm một khối điểm ảnh lạ từ bên ngoài chắc chắn sẽ làm xáo trộn và phá vỡ cấu trúc mẫu tự nhiên của bức ảnh gốc. Do đó, các thuật toán pháp y có thể phát hiện Splicing bằng cách truy tìm sự không nhất quán dọc theo các ranh giới cắt

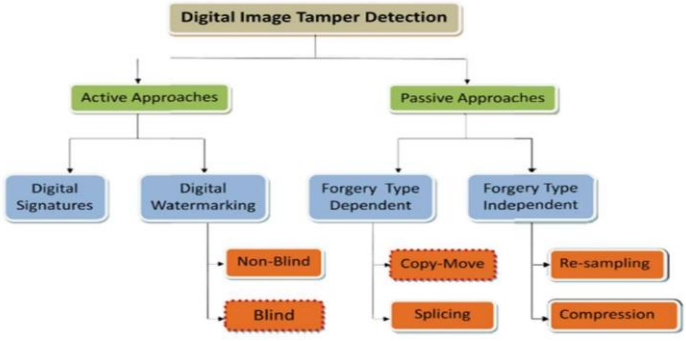
ghép, sự sai lệch về dấu vết cảm biến của camera, hoặc sự mâu thuẫn về điều kiện vật lý và ánh sáng



Hình 3: Ảnh minh họa kỹ thuật Splicing

2.3. Các phương pháp kiểm tra tính nguyên bản của hình ảnh

Để đối phó với những thách thức an toàn thông tin do việc thao túng và làm giả hình ảnh gây ra, lĩnh vực pháp y hình ảnh số (Digital Image Forensics) đã phát triển nhiều kỹ thuật khác nhau nhằm xác minh tính toàn vẹn và truy xuất nguồn gốc của hình ảnh. Các phương pháp kiểm định này được chia thành hai hướng tiếp cận chính: phương pháp chủ động (Active Approach) và phương pháp bị động (Passive Approach)(Muley S. R., 2024).



Hình 4: Sơ đồ phân loại các phương pháp kiểm tra tính nguyên bản của hình ảnh

2.3.1. Phương pháp chủ động

Phương pháp này dựa trên việc nhúng một số thông tin xác thực vào hình ảnh ngay tại thời điểm nó được tạo ra, thường là bởi các thiết bị phần cứng như camera,

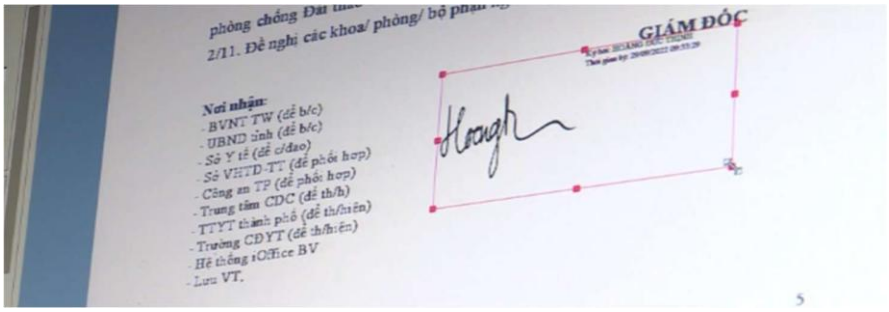
hoặc trước khi hình ảnh được phát tán. Trong phương pháp này, trước khi phát hành, ảnh sẽ được gắn thêm một chuỗi dữ liệu đặc biệt thông qua các kỹ thuật nhúng thông tin. Khi cần kiểm tra, hệ thống sẽ trích xuất và so sánh thông tin này với dữ liệu gốc để xác định xem ảnh có bị thay đổi hay không.

- Thủy vân số (Digital Watermarking): Một đoạn mã hoặc thông tin nhận dạng có thể ẩn hoặc hiện được nhúng trực tiếp vào dữ liệu hình ảnh. Nếu hình ảnh bị chỉnh sửa, cấu trúc của thủy vân sẽ bị phá vỡ, từ đó giúp phát hiện sự can thiệp.



Hình 5: Digital Watermarking trong ảnh

- Chữ kí số (Digital Signature): Sử dụng các thuật toán mã hóa để tạo ra một bản tóm tắt của nội dung ảnh. Bất kỳ thay đổi nào dù là nhỏ nhất trên các pixel cũng sẽ làm thay đổi giá trị chữ ký này, giúp xác minh tính toàn vẹn của dữ liệu.



Hình 6: Digital Signature trong tài liệu

Tuy phương pháp này có độ chính xác cao và khả năng phát hiện chỉnh sửa một cách trực tiếp nhưng tính thực tế của phương pháp này không cao trong môi trường tự do.Thứ nhất, nó đòi hỏi các thiết bị ghi hình phải được tích hợp sẵn công nghệ nhúng và không thể áp dụng cho hàng tỷ bức ảnh vô chủ hoặc ảnh cũ vốn không có mã nhúng từ trước.Thứ hai, Chữ kí số rất mạnh để xác minh tính thật giả nhưng nó không phổ biến vì không phải ai cũng sở hữu, Chữ kí số chưa phổ biến trong nhiếp ảnh dân dụng và thường chỉ ưu tiên cho các tài liệu văn bản pháp lý, vì vậy không thể dùng biện pháp so sánh chữ kí số để phát hiện hình đó có bị chỉnh sửa hay chưa.

2.3.2. Phương pháp thụ động

Khác với phương pháp chủ động, phương pháp thụ động hay còn gọi là Blind Forensics không yêu cầu bất kỳ thông tin nhúng sẵn hay kiến thức nào về hình ảnh gốc. Thay vào đó, phương pháp này dựa trên việc phân tích các đặc trưng nội tại của hình ảnh nhằm phát hiện dấu vết bất thường do quá trình chỉnh sửa gây ra. Các phương pháp bị động thường khai thác các đặc trưng như: Sự không nhất quán về ánh sáng hay bóng đổ, sự khác biệt về nhiễu cảm biến, các dấu vết nén JPEG, sự bất thường trong cấu trúc texture và thống kê pixel... Dựa trên các đặc trưng này, các thuật toán có thể xác định xem một hình ảnh có bị chỉnh sửa hay không, thậm chí trong một số trường hợp còn có thể định vị vùng bị chỉnh sửa. Dựa trên sơ đồ phân loại, phương pháp thụ động được chia thành hai nhóm nhỏ:

- Nhóm phụ thuộc loại giả mạo (Forgery Type Dependent): Tập trung vào việc truy tìm các dấu vết đặc trưng của từng kỹ thuật chỉnh sửa cụ thể.
- Nhóm không phụ thuộc loại giả mạo (Forgery Type Independent): Tập trung vào việc tìm kiếm các sai lệch về mặt thống kê của hình ảnh mà không quan tâm kẻ gian đã dùng kỹ thuật gì.

Phương pháp thụ động hoạt động dựa trên niềm tin là dù kẻ chỉnh sửa có tinh vi đến đâu, việc thay đổi các pixel cũng sẽ làm thay đổi các đặc trưng thống kê nội tại của ảnh hoặc để lại những dấu vết kĩ thuật kỹ thuật mà mắt thường không thấy nhưng máy tính có thể phân tích được.

Ưu điểm lớn nhất của phương pháp bị động là khả năng áp dụng rộng rãi cho mọi loại ảnh, kể cả các ảnh đã tồn tại từ trước. Tuy nhiên, độ chính xác phụ thuộc nhiều vào kỹ thuật sử dụng và có thể bị ảnh hưởng bởi các phép xử lý hậu kỳ như nén hoặc làm mờ. Trong nghiên cứu này, phương pháp bị động được lựa chọn làm hướng tiếp cận chính, cụ thể là khai thác các dấu vết nén JPEG kết hợp với mô hình học sâu để phát hiện ảnh bị chỉnh sửa.

2.4. Giải thuật nén chuẩn JPEG

2.4.1. Khái quát

Giải thuật nén JPEG[4] là một trong những phương pháp nén ảnh phổ biến nhất hiện nay, được sử dụng rộng rãi trong lưu trữ và truyền tải hình ảnh. JPEG là một phương pháp nén ảnh có tổn hao (lossy compression), quá trình nén JPEG bao gồm nhiều bước xử lý nhằm giảm dung lượng ảnh nhưng vẫn giữ được chất lượng thị giác ở mức chấp nhận được. nguyên lý sinh học cốt lõi của phương pháp này là dựa trên việc lợi dụng các điểm yếu của mắt người. Mắt người có hai loại tế bào cảm nhận ánh sáng:

- Tế bào que: Có khoảng 100 triệu tế bào đảm nhiệm việc cảm nhận độ sáng/tối.

[4] Video giải thích chi tiết giải thuật nén ảnh chuẩn JPEG: https://www.youtube.com/watch?v=Kv1Hiv3ox8I

- Tế bào nón: Chỉ có khoảng 6 triệu tế bào đảm nhiệm việc nhận diện màu sắc.

Vì vậy, mắt người cực kỳ nhạy cảm với độ sáng tối nhưng lại khá kém trong việc nhận biết các chi tiết màu sắc. Phương pháp này hoạt động dựa trên nguyên lý loại bỏ những chi tiết hình ảnh mà mắt người kém nhạy cảm như sự thay đổi màu sắc nhỏ hoặc các chi tiết tần số cao thay đổi quá nhanh.



Hình 7: Quy trình nén ảnh JPEG

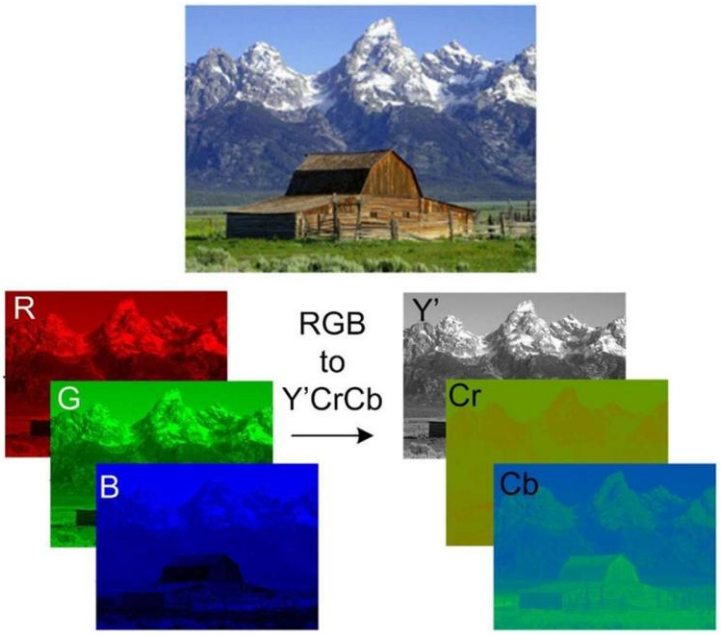
Quy trình nén ảnh gồm 5 bước diễn ra như sau: Đầu tiên là chuyển đổi ảnh cần nén từ hệ màu RGB sang YcbCr, sau đó tiến hành giảm mẫu ở hai kênh Cb và Cr. Sau khi giảm mẫu, thực hiện biến đổi Cosin rời rạc trên cả ba kênh Y, Cb và Cr. Sau bước này, ta thu được bảng Hệ số DCT. Sau khi có bảng hệ số này, tiến hành lượng tự hóa bảng hệ số bằng một bảng lượng tử được có sẵn. Cuối cùng, Run Length và mã hóa Entropy để lưu kết quả vào tệp ảnh JPEG. Khi mở ảnh, quá trình này sẽ đi ngược lại từ Run Length đến Chuyển đổi không gian màu để tái tạo lại ảnh.

2.4.2. Chuyển đổi không gian màu

Bản chất của bức ảnh gốc là một bức ảnh kỹ thuật số nguyên bản được tạo thành từ hàng triệu điểm ảnh (pixels). Ban đầu, mỗi điểm ảnh này được hệ thống biểu diễn bằng hệ màu RGB bao gồm 3 thành phần: Đỏ (Red), Xanh lá (Green) và Xanh dương (Blue). Mỗi thành phần màu mang một giá trị chạy từ 0 - 255, và sự pha trộn của 3 giá trị này sẽ quyết định màu sắc hiển thị cuối cùng của từng điểm ảnh.

Thay vì giữ nguyên hệ màu RGB, thuật toán sẽ lấy 3 giá trị R, G, B của từng điểm ảnh và dùng các công thức toán học để tính toán, chuyển đổi chúng sang một không gian gồm 3 giá trị hoàn toàn mới: Hệ màu YCbCr.

- Y (Luminance – Độ sáng): Kênh này chứa thông tin về độ sáng tối của bức ảnh.
- Cb (Blue Chrominance – Độ sắc xanh dương): Kênh chứa thông tin về màu xanh dương.
- Cr (Red Chrominance – Độ sắc đỏ): Kênh chứa thông tin về màu đỏ.



Hình 8: Ảnh minh họa Chuyển đổi không gian màu trong nén ảnh JPEG
(source: researchgate.net)

Công thức chuyển đổi theo tiêu chuẩn ITU-R BT.601 – Tiêu chuẩn phổ biến nhất được sử dụng trong nén ảnh JPEG:

$$Y = 0.299R + 0.587G + 0.114B$$
$$Cb = 128 - 0.168736R - 0.331264G + 0.5B$$
$$Cr = 128 + 0.5R - 0.418688G - 0.081312B$$

Trong đó:

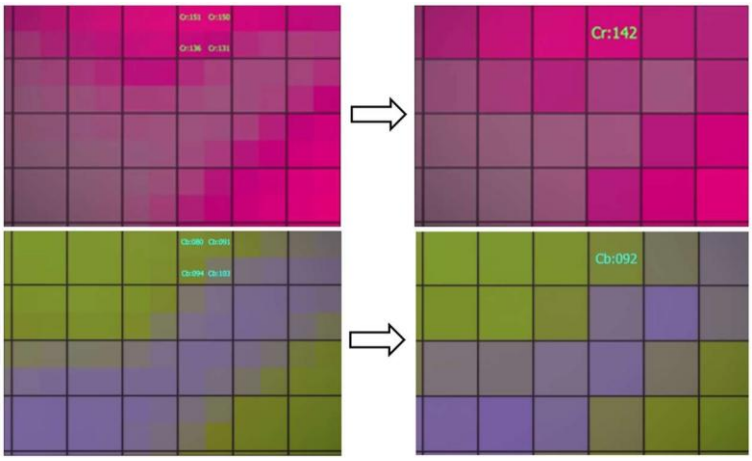
- R: Giá trị điểm ảnh của kênh Red.
- G: Giá trị điểm ảnh của kênh Green.
- B: Giá trị điểm ảnh của kênh Blue.
- Y, Cb, Cr: Giá trị điểm ảnh lần lượt của ba kênh YCbCr.

Theo nghiên cứu, mắt người nhạy cảm với sự thay đổi độ sáng hơn sự thay đổi màu sắc nên Nén JPEG sẽ giữ lại rất kĩ các hệ số ở kênh Y (hầu như không giảm mẫu) và mạnh tay giảm bớt hệ số ở hai kênh màu Cb, Cr.

2.4.3. Giảm mẫu

Giảm mẫu (Downsampling) là bước bắt đầu loại bỏ dữ liệu dựa trên nguyên lí mắt người kém nhạy cảm với sự thay đổi màu sắc nhỏ, chỉ áp dụng riêng cho hai kênh màu Cb và Cr. Quy trình thực hiện như sau:

- Bước 1: Lấy ảnh ở hai kênh Cb, Cb và chia thành các khối $2x2$ pixels.
- Bước 2: Tính giá trị pixel trung bình cho từng khối.
- Bước 3: Thu nhỏ hình ảnh lại sao cho giá trị trung bình của mỗi khối $2x2$ (4 pixels) giờ đây được gộp lại và chỉ chiếm 1 pixel duy nhất.



Hình 9: Ảnh minh họa bước Giảm mẫu trong nén ảnh JPEG

Kết quả là các dữ liệu của thành phần màu Cr và Cb bị thu nhỏ xuống chỉ còn một phần tư so với kích thước gốc, trong khi dữ liệu về độ sáng (ảnh kênh Y) vẫn được giữ nguyên.

2.4.4. Biến đổi Cosin rời rạc

Sau khi đã giảm bớt dữ liệu ở bước Down Sampling, thuật toán JPEG tiếp tục tiến đến bước phức tạp hơn mang tên Biến đổi Cosin rời rạc (Discrete Cosine Transform – viết tắt là DCT). Bước này tiến hành chuyển đổi dữ liệu hình ảnh từ miền không gian Pixel sang miền tần số để chuẩn bị cho bước Lượng tử hóa. Dưới đây là chi tiết từng bước thực hiện và hình ảnh ví dụ cụ thể cho từng bước:

Lưu ý: Các hình ảnh ví dụ được thực hiện chuyển đổi trên kênh độ sáng Y, các kênh Cb, Cr thực hiện tương tự.

* Chia khối (Spliting blocks):

Hình ảnh được chia nhỏ thành các khối (blocks) có kích thước 8x8. Mỗi khối này chứa 64 điểm ảnh, mỗi điểm ảnh có một giá trị biểu diễn ánh sáng hoặc màu sắc nằm trong khoảng từ 0 đến 255. Gọi Ma trận 8x8 điểm ảnh này là Bảng F .

Bảng 1: Bảng $\boldsymbol{F_1}$ giá trị ma trận 8x8 của một Block được chia từ ảnh

x \ y	0	1	2	3	4	5	6	7
0	37	36	37	42	47	50	55	61
1	37	37	38	44	49	52	54	57
2	38	39	44	52	56	57	56	56
3	37	44	56	65	68	67	62	59

4	43	57	72	83	85	80	73	66
5	54	57	97	105	102	93	84	77
6	72	101	117	116	111	105	95	85
7	91	115	124	121	116	108	100	92

* Chuyển đổi dãy giá trị (Shifting Block):

Lấy từng giá trị điểm ảnh trong khối trừ cho 128 nhằm dịch chuyển giá trị gốc về khoảng [-128, 127]. Sau khi chuyển đổi giá trị ban đầu, ta được bảng giá trị chuyển đổi (Shifted Block) gọi là Bảng F .

Bảng 2: Bảng giá trị $\boldsymbol{F_2}$ sau khi chuyển đổi giá trị

x \ y	0	1	2	3	4	5	6	7
0	-91	-92	-91	-86	-81	-78	-73	-67
1	-91	-91	-90	-84	-79	-76	-74	-71
2	-90	-89	-84	-76	-72	-71	-72	-72
3	-91	-84	-72	-63	-60	-61	-66	-69
4	-85	-71	-56	-45	-43	-48	-55	-62
5	-74	-71	-31	-23	-26	-35	-44	-51
6	-56	-27	-11	-12	-17	-23	-33	-43
7	-37	-13	-4	-7	-12	-20	-28	-36

* Chuyển đổi sang Hệ số tần số:

Từ bảng giá trị sau chuyển đổi (Shifted Block), áp dụng công thức chuyển đổi hệ số tần số ta được một bảng Hệ số tần số F tương ứng. Hệ số tại vị trí $F_{(,)}$ được tạo thành từ tổng của 64 phép nhân. Giá trị tại tọa độ $F_{(,)}$ được gọi là hệ số DC, thể hiện độ sáng trung bình của toàn bộ block. Còn 63 vị trí còn lại được gọi là hệ số AC – thể hiện các chi tiết gốc cạnh và vân ảnh.

- Công thức tính Hệ số DC: Cộng tất cả 64 điểm ảnh trong khối rồi chia 8.

$$F_{(\quad,)} = \frac{1}{8} \quad . \quad F_{(\ ,\ )} \ [\mathbf{1}]$$

Trong đó:

- $F_{(,)}$: Hệ số DCT tại tọa độ (u, v) trong bảng hệ số tần số F.
- u, v: Các chỉ số tần số chạy từ 0 đến 7.
- $F_{(,\quad\quad)}$: Giá trị pixel tại tọa độ (x, y) trong Bảng F .
- x, y: Các chỉ số vị trí pixel chạy từ 0 đến 7.

Ví dụ 1: Tính hệ số DC tại $\boldsymbol{F_{(0,0)}}$.

Áp dụng công thức [**1**], ta được:

$$\boldsymbol{F_{(0,0)}} = \frac{1}{8} . \quad . \quad F_{(\ ,\ )}$$

$$= \frac{(-91) + (-92) + (-91) + \ldots + (-67)}{8}$$

$$= -463$$

- Công thức tính Hệ số AC:

$$F_{(\quad,)} = _ . C\,C \sum \quad . \sum \quad F_{(\ ,\ )} . Cos \frac{0}{\quad} \Big] . Cos \frac{(\quad)}{\quad} \ [2]$$

$= \frac{1}{\sqrt{2}}$ C nếu $i = 0$ Trong đó: Hệ số chuẩn hóa C , C (gọi chung là C) với :

$\frac{(2.0 + 1).1.\pi}{16}$ $C = 1$ nếu $i > 0$

Ví dụ 2: Tính hệ số AC tại $\boldsymbol{F_{(1,0)}}$.

*Tại (x,y) = (0,0), ta có:

$$F_{(\ ,\ )} = (-91) \quad Cos \quad (20 + 1).0.\pi \ \text{Cos} \quad . \text{Cos} \frac{}{16} = \frac{\pi}{16}) \approx 0.98$$

→ $T = (-91)x\ 0.98 = -89.18$

*Tại (x,y) = (4,0), ta có:

$$F_{(,)} = (-85)\ (2.4+1).1.\pi \quad (20+1).0.\pi \cos\frac{9\pi}{16}\Big) \approx -0.19$$

$$\frac{\qquad}{16}\ .\ \text{Cos}\ \frac{\qquad}{16}\Big) = Cos$$

→ $T = (-85)\ x\ -\ (0.19) = 16.15$

....

*Tại (x,y) = (7,7), ta có:

$$F_{(,)} = (-36)\ (2.7+1).1.\pi \quad (2.7+1).0.\pi \cos\frac{15\pi}{16}\Big) \approx -0.98$$

$$\frac{\qquad}{16}\Big)\ .\ \text{Cos}\ \frac{\qquad}{16} = Cos$$

→ T = $(-36)\ x\ (-0.98) = 35.28$

Gọi $\mathbf{T} = \sum_{x\ 0}^{7}\sum_{0}^{7} \boldsymbol{F_{(x,y)}}.\ \boldsymbol{Cos}\ \frac{(2x+1)u\pi}{16}\ .\ \boldsymbol{Cos}\ \frac{(2y161)v\pi}{}$

= (−89.18) + (−0.19) + . . . + 35.28 ≈ −1028.01 Ta có:

Hệ số chuẩn hóa: $\frac{1}{4}$. C . C . = $\frac{1}{4}.1.\frac{1}{\sqrt{2}} \approx 0.176$

Thế vào công thức [2]:

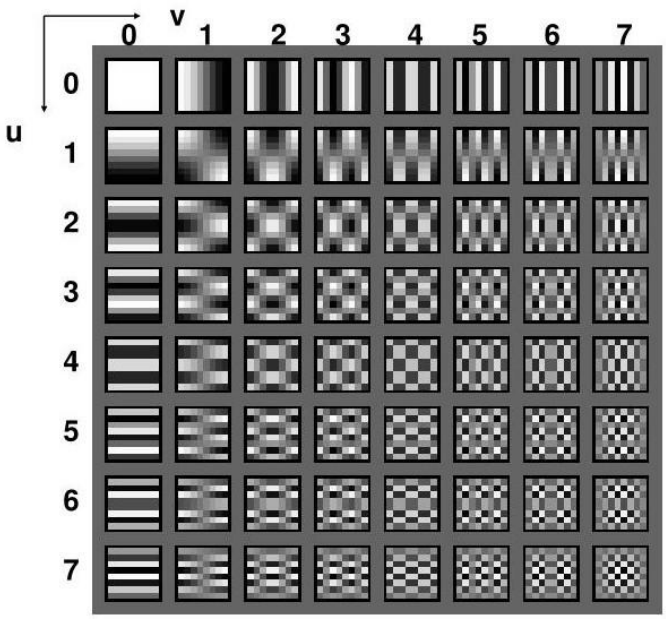
$$F_{(,)} = 0.176\ \text{x}\ (-1028.01) \approx -180.93$$

Thực hiện tương tự ví dụ trên cho tất cả 63 vị trí còn lại trong block, ta thu được bảng Hệ số DCT, gọi là Bảng *F*:

Bảng 3: Bảng Hệ số DCT *F*

v / u	0	1	2	3	4	5	6	7
0	-463.25	-41.49	-57.93	-12.69	-4.75	0.17	1.26	1.24
1	-180.93	-25.49	43.35	14.84	12.2	0.52	-0.42	-1.71
2	42.08	17.11	16.14	-3.83	-4.9	-4.74	-2.92	-1
3	-1.91	-12.49	-11.1	-3.22	3.59	4.92	4.27	2.97
4	1.5	2.56	4.83	1.26	-1	-3.31	-3.36	-1.57
5	1.75	0.41	-1.2	-2.21	-2.7	-0.94	0.12	-0.51
6	-2.28	-3.57	-1.67	0.37	5.82	5	4.11	2.82
7	2.99	3.65	2.56	0.5	-3.7	-4.04	-4.34	-2.35

Trong Bảng 3, hệ số tại vị trí $F_{(,)}$ được gọi là hệ số DC, những vị trí còn lại là AC. Lưu ý, các giá trị này không phải là mức độ đóng góp của sóng Cosin tại vị trí đó đối với toàn bộ block. Những vị trí có hệ số nhỏ có nghĩa là sóng đó không đóng góp nhiều vào toàn bộ khối, nếu triệt tiêu những sóng này thì sẽ không nhận thấy sự khác biệt.



Hình 10: Based Image hay Bảng đồ sóng Cosin dùng để tái tạo ảnh từ Bảng hệ số DCT

2.4.5. Lượng tử hóa

* Bảng lượng tử

Trong chuẩn JPEG không dùng một con số duy nhất cho cả block. Thay vào đó, ta dùng một ma trận 8x8 tương ứng với ma trận Hệ số DCT, ma trận này được gọi là Bảng lượng tử (Quantization Table). Trong tệp ảnh JPEG, Bảng lượng tử hóa được lưu ở phần Header của tệp.

Khi chụp ảnh, phần mềm xử lý hình ảnh của thiết bị sẽ quyết định bảng lượng tử. Mỗi hãng máy ảnh như Canon, Nikon, Sony, hay điện thoại Apple,... đều có những bảng lượng tử riêng, các giá trị trong bảng được hãng tinh chỉnh sẵn để ảnh chụp ra có màu sắc và độ nét đặc trưng của hãng. Khi chỉnh sửa và lưu lại ảnh, lúc này Bảng lượng tử của máy ảnh gốc sẽ bị bỏ đi, Bảng lượng tử mới sẽ do phần mềm chỉnh sửa quyết định.

Bảng lượng tử được thiết kế có chủ đích với các con số nhỏ nằm ở góc trên cùng bên trái tương ứng với dữ liệu tần số thấp, chứa các mẫu hình ảnh rõ rệt và các con số lớn hơn nằm ở góc dưới cùng bên phải tương ứng với dữ liệu tần số cao mà mắt người không nhạy bén trong việc nhận biết.

Thuật toán sử dụng hai Bảng lượng tử hóa: một bảng dành cho kênh độ sáng và một bảng dành cho kênh màu sắc. Bảng của thành phần màu sắc chứa các giá trị lớn hơn hẳn so với bảng độ sáng vì giá trị tần số màu sắc được loại bỏ nhiều hơn.

Bảng 4: Ví dụ Bảng lượng tử Q với quality = 95

v / u	0	1	2	3	4	5	6	7
0	2	1	1	2	2	4	5	6
1	1	1	1	2	3	6	6	6
2	1	1	2	2	4	6	7	6
3	1	2	2	3	5	9	8	6
4	2	2	4	6	7	11	10	8
5	2	4	6	6	8	10	11	9
6	5	6	8	9	10	12	12	10
7	7	9	10	10	11	10	10	10

Khi thay đổi mức độ nén (quality) của bức ảnh, các giá trị bên trong bảng lượng tử hóa sẽ được thay đổi theo.

* Quy trình Lượng tử hóa

Mỗi hệ số trong ma trận Hệ số DCT (Bảng **F**) sẽ được chia cho một giá trị tương ứng trong Bảng lượng tử Q, sau đó làm tròn thành số nguyên gần nhất. Kết quả thu được là Bảng hệ số DCT đã lượng tử hóa Q (Quantized Table)

$$Q(\quad,\quad) = Round\left(\frac{F(\quad,\quad)}{Q(\quad,\quad)}\right)$$

Ví dụ 3: Từ bảng hệ số DCT F và bảng lượng tử Q. Tính $\boldsymbol{Q_1}$.

Áp dụng công thức, ta được:

$$Q(,) = Round\left(\frac{F(,)}{Q(,)}\right) = Round\left(\frac{-463.25}{2}\right) = Round(-231.625) = -232$$

$$Q(,) = Round\left(\frac{F(,)}{Q(,)}\right) = Round\left(\frac{-41.49}{1}\right) = Round(-41.49) = -41$$

...

$$Q(,) = Round\left(\frac{F(,)}{Q(,)}\right) = Round\left(-4.34\right) = Round(-0.434) = 0$$

$$Q_{(,)} \qquad \overline{10}$$

$$Q_{(,)} = Round\left(\frac{F_{(,)}}{Q_{(,)}}\right) = Round\left(\frac{-2.35}{10}\right) = Round(-0.2.35) = 0$$

Bảng 5: Bảng kết quả $\boldsymbol{Q_1}$ sau bước lượng tử hóa của ví dụ 3

v / u	0	1	2	3	4	5	6	7
0	-232	-41	-58	-6	-2	0	0	0
1	-181	-25	43	7	4	0	0	0
2	42	17	8	-2	-1	-1	0	0
3	-2	-6	-6	-1	1	1	1	0
4	1	1	1	0	0	0	0	0
5	1	0	0	0	0	0	0	0
6	0	-1	0	0	1	0	0	0
7	0	0	0	0	0	0	0	0

Việc lượng tử hóa các hệ số DCT và thực hiện phép làm tròn đến số nguyên gần nhất dẫn đến sự triệt tiêu vĩnh viễn các thành phần thập phân, khiến đây trở thành một quá trình biến đổi không lấy lại được giá trị ban đầu. Đây chính là giai đoạn cốt lõi của giải thuật nén ảnh có tổn hao (lossy compression), tạo ra các sai số tái tạo so với dữ liệu gốc. Đây chính là nguồn gốc của các đặc trưng phục vụ cho bài toán phân tích tính nguyên bản của hình ảnh.

2.4.6. Run length và Mã hóa Entropy

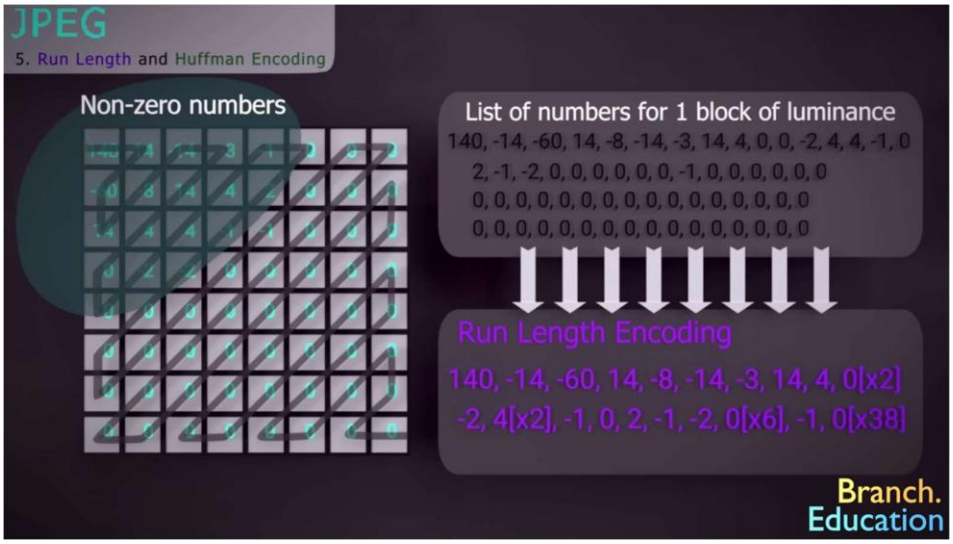
Sau khi thu được ma trận hệ số DCT đã lượng tử hóa (Quantized Table), khối dữ liệu 8x8 lúc này chỉ còn lại một vài con số nằm ở góc trên cùng bên trái và rất nhiều số 0. Để đóng gói khối dữ liệu này thành định dạng nhỏ gọn nhất, thuật toán thực hiện tuần tự các bước sau:

Đọc dữ liệu theo đường ZigZag: Thay vì đọc ma trận theo từng hàng ngang hay cột dọc thông thường, thuật toán sẽ liệt kê các giá trị trong block $8x8$ theo một đường ZigZag. Thao tác này giúp tập hợp tất cả các hệ số khác 0 lên đầu danh sách và đẩy

toàn bộ các chuỗi số 0 về phía cuối, tạo cấu trúc dữ liệu cực kỳ thuận lợi cho các bước nén tiếp theo.

Mã hóa Run Lenght: Tận dụng danh sách đã được sắp xếp, thuật toán RLE giúp thu gọn dữ liệu bằng cách thay thế các chuỗi số 0 lặp lại liên tiếp. Thay vì lưu trữ từng số 0 riêng lẻ, thuật toán chỉ ghi lại số lượng các số 0 xuất hiện trước một giá trị khác 0, giúp giảm thiểu đáng kể số lượng ký hiệu cần xử lý.

Mã hóa Huffman: Đây là bước chuyển đổi cuối cùng để đưa các ký hiệu dữ liệu thành dòng bit nhị phân thực tế để lưu trữ trên ổ cứng. Thuật toán dựa trên tần suất xuất hiện để gán các chuỗi bit ngắn cho những giá trị phổ biến và chuỗi bit dài hơn cho các giá trị hiếm gặp. Quá trình này giúp triệt tiêu tối đa sự dư thừa dữ liệu mà vẫn đảm bảo giữ nguyên vẹn toàn bộ thông tin đã có sau bước lượng tử hóa.



Hình 11: Minh họa Quét ZigZag và mã hóa Run Lenght trong thuật toán nén JPEG

Sau khi thực hiện quá trình nén, ảnh được lưu dưới dạng tệp JPEG. Khi hiển thị, hệ thống sẽ tiến hành giải nén bằng cách thực hiện ngược lại các bước trong quy trình nén nhằm tái tạo lại hình ảnh ban đầu. Tuy nhiên, do bước lượng tử hóa đã làm tròn các giá trị hệ số DCT, một phần thông tin của ảnh đã bị mất đi không thể khôi phục hoàn toàn. Vì vậy, ảnh sau khi giải nén sẽ có sự sai khác nhất định so với ảnh gốc.s



Hình 12: Sự khác biệt giữa các chất lượng nén trên ảnh

2.5. Dấu vết nén trong ảnh JPEG

Trong quá trình nén ảnh JPEG, dữ liệu hình ảnh được biến đổi qua nhiều bước xử lý như chuyển đổi không gian màu, chia khối, biến đổi Cosine rời rạc (DCT) và lượng tử hóa. Đặc biệt, bước lượng tử hóa đóng vai trò quan trọng trong việc giảm dung lượng ảnh bằng cách làm tròn các hệ số tần số, nhưng đồng thời cũng là nguyên nhân chính gây ra mất mát thông tin. Sự mất mát này không thể phục hồi trong quá trình giải nén, dẫn đến sự xuất hiện của các Dấu vết nén đặc trưng trên ảnh.

Các dấu vết nén là những sai khác nhỏ về giá trị pixel so với ảnh gốc, thường khó nhận biết bằng mắt thường nhưng có thể phân tích bằng các phương pháp toán học. Trong trường hợp một ảnh chỉ được nén một lần với cùng một mức chất lượng từ máy ảnh, các dấu vết nén này sẽ phân bố tương đối đồng đều trên toàn bộ bức ảnh. Điều này là do tất cả các khối ảnh đều trải qua cùng một quy trình biến đổi DCT và cùng một bảng lượng tử hóa.

Tuy nhiên, khi một bức ảnh bị chỉnh sửa như Splicing và Copy-Move, các vùng bị can thiệp thường có lịch sử xử lý khác so với phần còn lại của ảnh. Nguyên nhân cốt lõi tạo ra dấu vết giả mạo nằm ở quá trình nén kép (Double Compression) và sự khác biệt về lịch sử nén khi kẻ gian lưu lại bức ảnh.

- Đối với vùng nền gốc: Vùng ảnh này vốn dĩ đã bị nén một lần ngay từ khi bức ảnh được chụp bởi thiết bị camera. Khi kẻ gian thực hiện xong thao tác chỉnh sửa và nhấn lưu ảnh lại, phần mềm sẽ nén toàn bộ bức ảnh lại. Lúc này, vùng nền gốc tiếp tục bị nén thêm lần thứ hai, trải qua quá trình nén hai lần (Double Compression).
- Đối với vùng cắt dán: Bất kể vùng ảnh này trước đó đã từng bị nén hay chưa, các thao tác cắt, dán và hậu xử lý của kẻ gian (như xoay, thu phóng, làm mờ viền) đều được thực hiện trực tiếp trên miền điểm ảnh. Việc dán vật thể vào một vị trí mới sẽ làm xô lệch hệ thống lưới 8x8 pixel nguyên bản của chuẩn nén JPEG, từ đó phá vỡ hoàn toàn cấu trúc hệ số DCT cũ. Do đó, ở lần lưu cuối cùng, khi phần mềm áp một lưới nén 8x8 mới lên toàn bộ bức ảnh để tính toán lại từ đầu, vùng cắt dán này thực chất mới chỉ đang trải qua quá trình nén một lần (Single Compression) dưới một bảng lượng tử hóa mới.

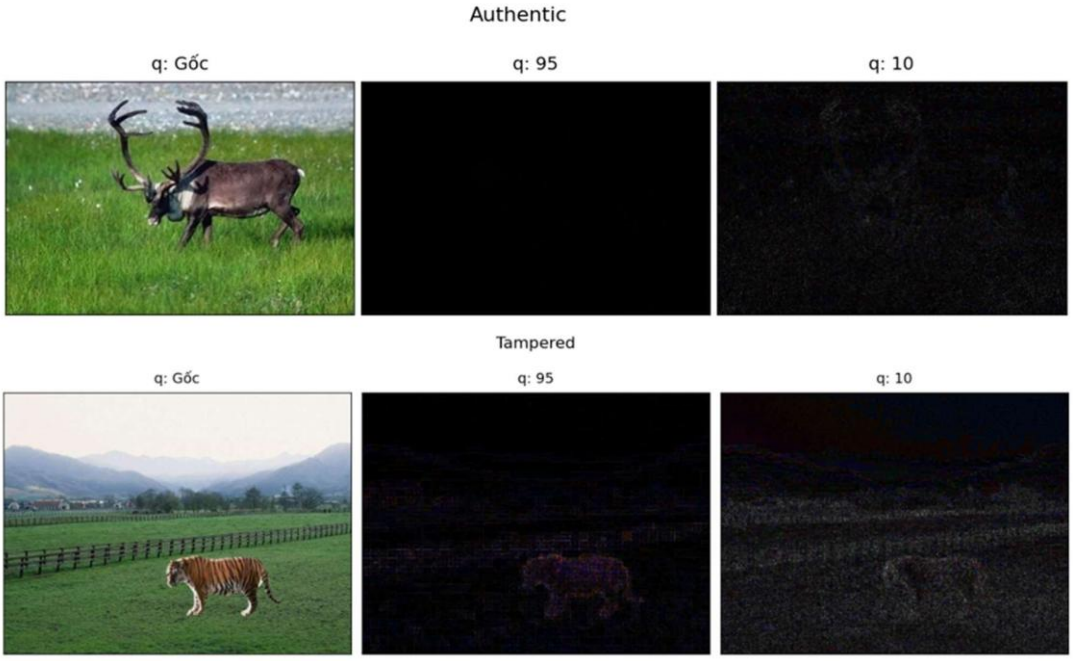
Sự khác biệt về số lần nén trong lịch sử này khiến cho các vùng trong ảnh phản ứng hoàn toàn khác nhau nếu tiếp tục bị tác động. Các khối điểm ảnh thuộc vùng nền (nén 2 lần) đã tiệm cận đến trạng thái "cực tiểu cục bộ" hay trạng thái bão hòa, nên sẽ tạo ra sai số rất nhỏ nếu bị nén thêm. Ngược lại, vùng bị cắt dán (nén 1 lần) chưa bão hòa, do đó sẽ tạo ra sai số và biến dạng lớn hơn rất nhiều nếu tiếp tục bị ép nén. Sự bất đồng nhất giữa hai vùng này chính là mấu chốt để các thuật toán pháp y số định vị khu vực giả mạo.

2.6. Kỹ thuật Error Level Analysis

2.6.1. Khái niệm

Phân tích mức độ lỗi – Error Level Analysis (ELA) là một kỹ thuật trong lĩnh vực pháp y ảnh số (Digital image forensics), được sử dụng để phát hiện các dấu hiệu chỉnh sửa trong ảnh kỹ thuật số, đặc biệt là ảnh định dạng JPEG. Ý tưởng cốt lõi của ELA là đánh giá mức độ sai khác của các điểm ảnh giữa ảnh ban đầu và ảnh sau khi được tái nén. Trong điều kiện lý tưởng, nếu một bức ảnh chưa bị chỉnh sửa, các vùng trong ảnh sẽ có mức độ nén tương đối đồng đều do cùng trải qua một quy trình xử lý. Ngược lại, khi ảnh bị can thiệp, chẳng hạn như cắt ghép, chèn đối tượng hoặc chỉnh sửa cục bộ, các vùng bị tác động sẽ mang đặc trưng nén khác biệt, dẫn đến sự không nhất quán trong phân bố sai số.

ELA tận dụng đặc điểm này bằng cách tạo ra một ảnh biểu diễn mức sai khác (Error map), trong đó các vùng có sai khác lớn sẽ được làm nổi bật. Nhờ đó, ELA cho phép quan sát trực quan các khu vực có khả năng đã bị chỉnh sửa. Trong nghiên cứu nay, error được gọi là Ảnh sai khác chất lượng nén.



Hình 13: Minh hoạ ảnh sai khác chất lượng nén của ảnh thật và ảnh bị chỉnh sửa

Trong những năm gần đây, ELA không chỉ được sử dụng như một công cụ hỗ trợ phân tích thủ công mà còn được tích hợp vào các hệ thống học máy và học sâu. Đặc biệt, việc sử dụng ảnh ELA làm đầu vào cho các mô hình học sâu giúp tăng cường khả năng phát hiện các dấu vết giả mạo, do các đặc trưng liên quan đến nén được làm nổi bật rõ ràng hơn so với ảnh RGB thông thường.

2.6.2. Nguyên lí hoạt động

Nguyên lý hoạt động của ELA dựa trên việc khai thác sự không nhất quán trong đặc trưng nén giữa các vùng của ảnh. Khi một ảnh JPEG được tái nén với cùng một mức chất lượng, các vùng có đặc trưng nén tương đồng sẽ tạo ra sai số tương tự nhau, trong khi các vùng có lịch sử nén khác biệt sẽ tạo ra sai số khác biệt.

Để định lượng sự sai khác này, ELA sử dụng phép toán so sánh trực tiếp giữa ảnh gốc và ảnh sau khi tái nén. Công thức tính ảnh sai khác chất lượng nén như sau:

$$ELA(x, y) = |I(x, y) - I\ (x, y)|$$ Trong đó:

- $I(x, y)$: Giá trị pixel tại vị trí (x,y) của ảnh gốc.
- $I\ (x, y)$: Giá trị pixel tương ứng của ảnh sau khi nén. - $ELA(x, y)$: Ảnh sai khác chất lượng nén.

Giá trị $ELA(x, y)$ càng lớn cho thấy mức độ thay đổi càng cao giữa hai ảnh, từ đó phản ánh khả năng tồn tại sự bất thường tại vị trí tương ứng. Trong thực tế, mặc dù có sự chênh lệnh Pixel giữa ảnh trước và sau khi nén, các giá trị sai số vẫn rất nhỏ để mắt người có thể nhìn thấy, vì vậy, ảnh ELA thường được chuẩn hóa hoặc nhân với một hệ số khuếch đại để tăng khả năng quan sát.

Lưu ý: ELA không trực tiếp xác định vùng giả mạo, mà chỉ cung cấp thông tin về mức độ sai khác. Do đó, việc phân tích kết quả ELA thường cần kết hợp với các phương pháp khác hoặc sử dụng các mô hình học sâu để đưa ra kết luận chính xác hơn.

2.6.3. Quy trình thực hiện

Quy trình thực hiện kỹ thuật ELA bao gồm các bước xử lý tuần tự từ tiền xử lý ảnh đến tạo ảnh sai khác. Các bước này có thể được mô tả như sau:

Bước 1: Đọc ảnh đầu vào.

Bước 2: Ảnh được nén lại bằng thuật toán JPEG với một mức chất lượng xác định. Mức chất lượng này cần được lựa chọn phù hợp để đảm bảo vừa giữ được đặc trưng ảnh và cũng phải vừa tạo ra sai khác đủ lớn để phân tích. Mức chất lượng phổ biến là từ 90 đến 95.

Bước 3: Ảnh sau khi nén sẽ được giải mã (giải nén) để đưa về không gian pixel, tạo thành ảnh I .

Bước 4: Thực hiện phép trừ tuyệt đối giữa ảnh gốc $\boldsymbol{I}$ và ảnh tái nén $\boldsymbol{I_{Co}}$ theo công thức. Kết quả thu được là một ảnh biểu diễn mức sai khác tại từng điểm ảnh.

Bước 5: Ảnh sai khác thu được từ quá trình ELA thường có giá trị cường độ pixel nhỏ, dẫn đến khó quan sát bằng mắt thường. Do đó, để làm nổi bật các vùng có sai khác, ảnh ELA thường được tăng cường bằng cách nhân với một hệ số hoặc thực hiện chuẩn hóa cường độ. Việc tăng cường này giúp làm rõ các khu vực có mức sai khác cao, từ đó hỗ trợ quá trình phân tích trực quan cũng như cải thiện hiệu quả khi sử dụng làm đầu vào cho các mô hình học sâu. Tuy nhiên, cần lựa chọn hệ số khuếch đại một cách phù hợp, bởi nếu tăng cường quá mức có thể làm khuếch đại cả nhiễu và

các sai khác không đáng kể, dẫn đến khó phân biệt giữa vùng bất thường và vùng nguyên bản.

Ảnh sai khác chất lượng nén sau khi xử lý có thể được sử dụng theo hai hướng:

- Phân tích trực quan để xác định vùng nghi ngờ.
- Làm đầu vào cho các mô hình học sâu nhằm tự động phân loại ảnh.

Trong nghiên cứu này, tôi sử dụng ảnh sai khác chất lượng nén làm đầu vào (input) cho các mô hình CNN. Việc này giúp mô hình tập trung vào các dấu vết nén thay vì nội dung ngữ nghĩa của ảnh, từ đó nâng cao khả năng phát hiện ảnh giả mạo.

2.7. Mạng nơ-ron tích chập

2.7.1. Định nghĩa

Mạng nơ-ron tích chập (Convolutional Neural Network – CNN) là một kiến trúc học sâu được thiết kế chuyên biệt để xử lý dữ liệu dạng lưới, đặc biệt là hình ảnh. Khác với các mạng nơ-ron truyền thống, CNN có khả năng khai thác mối quan hệ không gian giữa các điểm ảnh thông qua các phép toán tích chập, từ đó giúp mô hình học được các đặc trưng hiệu quả hơn.

Trong xử lý ảnh, dữ liệu đầu vào thường được biểu diễn dưới dạng ma trận hai chiều hoặc ba chiều. CNN sử dụng các bộ lọc (kernel) nhỏ trượt trên ảnh để phát hiện các đặc trưng cục bộ như cạnh, góc và kết cấu. Nhờ cơ chế chia sẻ trọng số, CNN giảm đáng kể số lượng tham số cần học so với các mạng fully connected, đồng thời vẫn giữ được khả năng biểu diễn mạnh mẽ. Trong nghiên cứu này, CNN được sử dụng để học các đặc trưng từ Ảnh sai khác chất lượng nén, từ đó phân biệt giữa ảnh nguyên bản và ảnh đã bị chỉnh sửa dựa trên các dấu vết nén.

2.7.2. Các thành phần chính của CNN

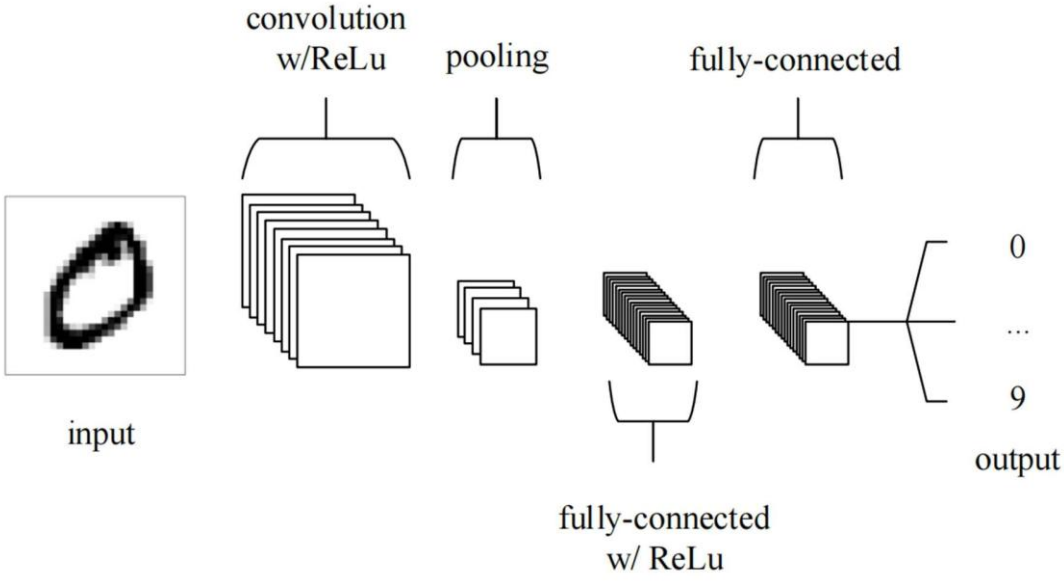
Một kiến trúc CNN hoàn chỉnh được tạo nên từ sự xếp chồng của 3 loại lớp chính: Lớp Tích chập, lớp Gộp và lớp Kết nối đầy đủ. Ngoài ra, các hàm kích hoạt như ReLU và Sigmoid được sử dụng để tăng khả năng biểu diễn của mô hình.

Lớp tích chập (Convalutional Layer): là thành phần cốt lõi của CNN, có nhiệm vụ trích xuất các đặc trưng từ ảnh đầu vào thông qua các bộ lọc (filters). Mỗi bộ lọc sẽ quét qua toàn bộ ảnh và phản hồi mạnh với một loại đặc trưng cụ thể như cạnh, góc hoặc texture. Các bộ lọc này không được thiết kế thủ công mà được học tự động trong quá trình huấn luyện. Nhờ đó, CNN có khả năng thích nghi với dữ liệu và học được các đặc trưng phù hợp cho từng bài toán cụ thể.

Lớp gộp (Pooling Layer): Có nhiệm vụ giảm kích thước không gian của feature map, từ đó giảm số lượng tham số và chi phí tính toán. Đồng thời, lớp này giúp mô hình trở nên ổn định hơn trước các biến đổi nhỏ của dữ liệu đầu vào. Lớp Gộp đóng vai trò quan trọng trong việc giảm độ phức tạp của mô hình và hạn chế hiện tượng overfitting. Lớp Gộp có 2 phương pháp phổ biến:

- Max Pooling: chọn giá trị lớn nhất trong một vùng nhỏ. Phương pháp này giúp giữ lại các đặc trưng nổi bật nhất và thường được sử dụng rộng rãi trong CNN.
- Average Pooling: tính giá trị trung bình của các phần tử trong vùng. Phương pháp này giúp giữ lại thông tin tổng quát hơn nhưng có thể làm mờ các đặc trưng quan trọng.

Lớp kết nối đầy đủ (Fully Connected Layer): Trong lớp này, mỗi nơ-ron được kết nối với tất cả các nơ-ron ở lớp trước đó. Đây là nơi thực hiện quá trình phân loại dựa trên các đặc trưng đã được trích xuất, kết hợp các đặc trưng đã học để đưa ra quyết định cuối cùng. Trong bài toán phân loại ảnh, lớp cuối cùng thường xuất ra xác suất thuộc về từng lớp. Tuy nhiên, do số lượng tham số lớn, các lớp kết nối đầy đủ dễ gây overfitting, vì vậy thường được sử dụng với số lượng hạn chế hoặc kết hợp với các kỹ thuật regularization.



Hình 14: Ảnh minh họa kiến trúc cơ bản của CNN (O'Shea et al. 2015)

2.7.3. Cơ chế học đặc trưng

Một trong những ưu điểm nổi bật của CNN là khả năng học đặc trưng theo cấp bậc:

- Các lớp đầu: Thường học các đặc trưng mức thấp như cạnh và góc.
- Các lớp trung gian: Kết hợp các đặc trưng học được từ các lớp đầu để tạo thành các cấu trúc phức tạp hơn.
- Các lớp sâu hơn: học các đặc trưng mức cao liên quan đến đối tượng trong ảnh.

Quá trình này giúp CNN tự động trích xuất đặc trưng mà không cần thiết kế thủ công. Trong bài toán phát hiện ảnh giả mạo, khi sử dụng ảnh ELA làm đầu vào, CNN

có thể học được các đặc trưng liên quan đến sự không nhất quán trong dấu vết nén giữa các vùng ảnh, từ đó nâng cao khả năng phân biệt giữa ảnh thật và ảnh giả.

2.7.4. Hàm kích hoạt

Hàm kích hoạt (Activation Function) đóng vai trò quan trọng trong việc đưa tính phi tuyến vào mô hình. Nếu không có hàm kích hoạt, toàn bộ mạng CNN chỉ tương đương với một phép biến đổi tuyến tính, không đủ khả năng biểu diễn các mối quan hệ phức tạp.

* Hàm ReLU:

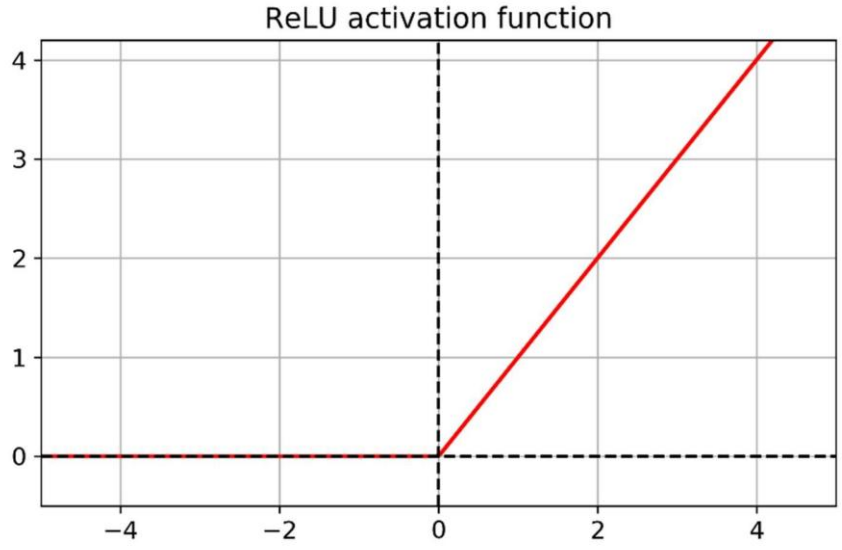
Hàm ReLU được định nghĩa như sau:

$$f(x) = \max(0, x)$$

Trong đó, x là giá trị đầu vào của hàm kích hoạt và $f(x)$là giá trị đầu ra.

- Nếu $x < 0$ thì đầu ra bằng 0. -
Nếu $x \geq 0$ thì đầu ra = x.

Ưu điểm chính của ReLU so với các hàm kích hoạt khác như Sigmoid hoặc Tanh là khả năng giảm thiểu hiện tượng vanishing gradient. Hiện tượng này xảy ra khi gradient trở nên rất nhỏ trong quá trình lan truyền ngược, làm cho việc cập nhật trọng số trở nên chậm và ảnh hưởng đến quá trình học của mạng sâu. ReLU khắc phục vấn đề này bằng cách cho phép gradient truyền qua mà không bị suy giảm đối với các giá trị đầu vào dương, từ đó giúp tăng tốc độ hội tụ trong quá trình huấn luyện.



Hình 15: Ảnh minh họa biểu đồ của hàm ReLU

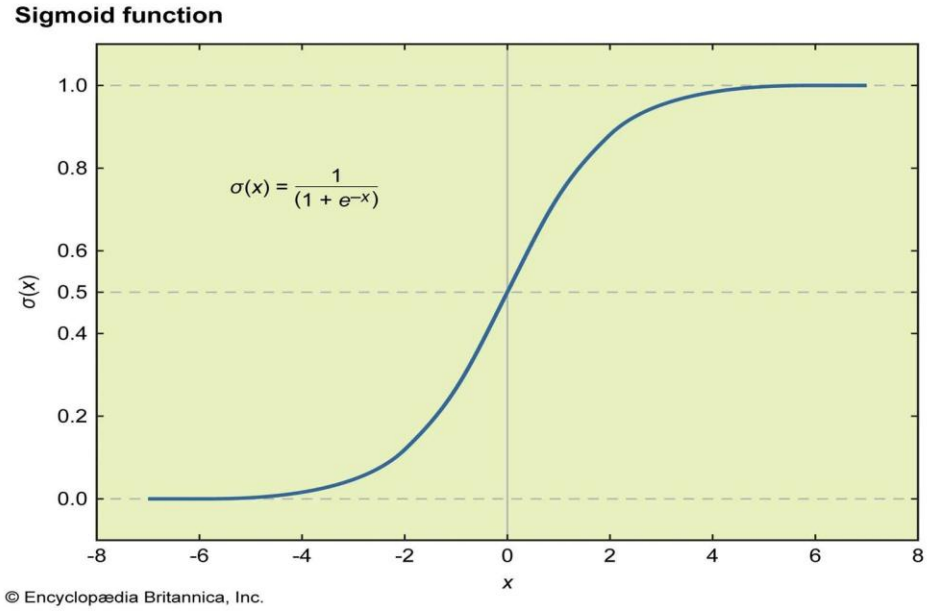
* Hàm Sigmoid:

Hàm Sigmoid được định nghĩa như sau:

$$\sigma(x) = \frac{1}{1 + e}$$

Trong đó, x là giá trị đầu vào, e là hằng số Euler và $\sigma(x)$là giá trị đầu ra của hàm. Hàm Sigmoid có đặc điểm ánh xạ mọi giá trị đầu vào về khoảng [0,1].

- Khi $x \to +\infty$ thì $\sigma(x) \to 1$.
- Khi $x \to -\infty$ thì $\sigma(x) \to 0$.



Hình 16: Ảnh minh họa biểu đồ hàm Sigmoid

2.7.5. Hàm mất mát

Hàm mất mát (Loss Function) là đại lượng đo lường sự sai lệch giữa dự đoán của mô hình và nhãn thực tế. Đây là cơ sở để mô hình học và điều chỉnh các trọng số. Trong nghiên cứu này, Loss Function được sử dụng là Binary Cross-Entropy, được định nghĩa như sau:

$$L = -[ylogy + (1 - y)\log(1 - y)]$$

Trong đó, y là nhãn thực tế (0 hoặc 1), y là giá trị dự đoán của mô hình (đầu ra của hàm Sigmoid). Hàm mất mát này đo lường mức độ khác biệt giữa xác suất dự đoán và giá trị thực tế. Cụ thể:

- Nếu mô hình dự đoán đúng y=1 và $y \approx 1$, giá trị của hàm mất mát sẽ rất nhỏ.
- Nếu mô hình dự đoán sai y=1 và $y \approx 0$, giá trị của hàm mất mát sẽ tăng lên đáng kể.

Hàm Binary Cross-Entropy thường được sử dụng kết hợp với hàm Sigmoid trong lớp đầu ra, do cả hai cùng hoạt động trên miền xác suất [0,1]. Sự kết hợp này giúp mô hình học hiệu quả hơn trong các bài toán phân loại nhị phân. Giá trị của hàm mất mát sẽ được sử dụng trong quá trình lan truyền ngược để tính toán gradient, từ đó cập nhật các trọng số của mô hình theo hướng giảm sai số.

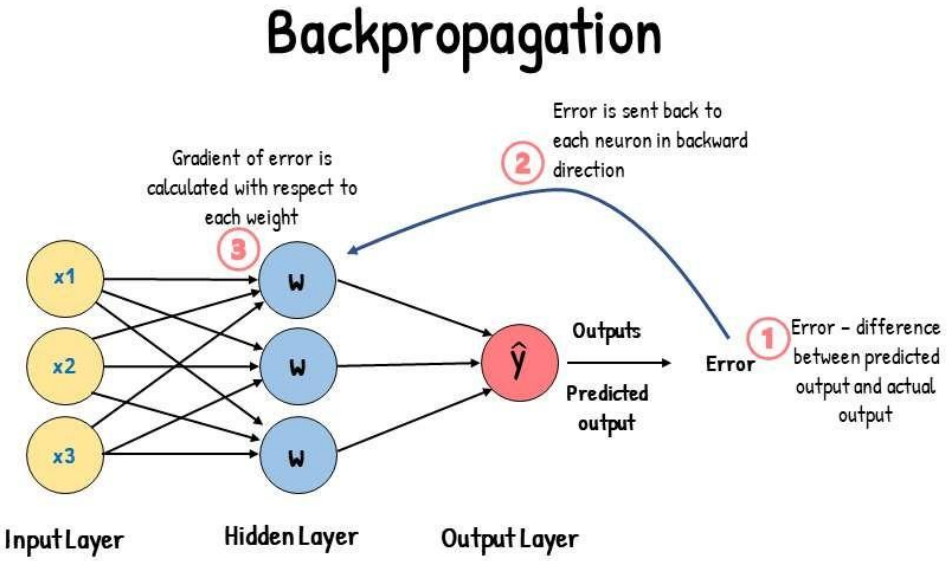
2.7.6. Cơ chế lan truyền ngược

Để CNN có thể học được các đặc trưng phù hợp, mô hình cần được huấn luyện thông qua cơ chế lan truyền ngược (Backpropagation). Đây là quá trình cập nhật trọng số dựa trên sai số giữa giá trị dự đoán và giá trị thực tế. Quá trình này giúp mô hình dần dần học được các tham số tối ưu nhằm giảm thiểu hàm mất mát.

Quá trình huấn luyện của mạng CNN bao gồm hai giai đoạn chính: lan truyền xuôi (Forward pass) và lan truyền ngược (Backward pass). Trong giai đoạn lan truyền xuôi, dữ liệu đầu vào được truyền qua các lớp của mạng để tạo ra giá trị dự đoán. Sau đó, hàm mất mát được sử dụng để tính toán sai số giữa dự đoán và nhãn thực tế. Trong giai đoạn lan truyền ngược, sai số này được truyền ngược từ lớp đầu ra về các lớp trước đó. Mục tiêu của quá trình này là xác định mức độ ảnh hưởng của từng trọng số đến sai số tổng thể, từ đó điều chỉnh các trọng số theo hướng làm giảm hàm mất mát. Việc cập nhật trọng số được thực hiện dựa trên gradient của hàm mất mát theo từng trọng số, theo công thức:

$$w = w - \eta . \frac{\partial L}{\partial w}$$

Trong đó: w trọng số, η tốc độ học (learning rate), $\frac{\partial L}{\partial w}$ là đạo hàm của hàm mất mát theo trọng số. Gradient cho biết hướng và mức độ cần thay đổi của trọng số để giảm sai số.



Hình 17: Minh họa cơ chế Backpropagation (nguồn: botpenguin.com)

Quá trình này được thực hiện lặp lại nhiều lần trên toàn bộ tập dữ liệu huấn luyện. Qua mỗi lần lặp, các trọng số được điều chỉnh dần dần, giúp mô hình cải thiện khả năng dự đoán. Trong nghiên cứu này, cơ chế lan truyền ngược đóng vai trò quan trọng trong việc giúp mô hình CNN học được các đặc trưng phân biệt giữa ảnh thật và ảnh giả dựa trên dữ liệu ELA, từ đó nâng cao hiệu quả của hệ thống phát hiện.

2.8. Transfer Learning

2.8.1. Khái niệm

Học chuyển giao (Transfer learning): là một kỹ thuật trong Machine Learning, trong đó, các kiến thức đã thu được thông qua một bài toán hay một tập dữ liệu được sử dụng để cải thiện hiệu suất mô hình trên bài toán có liên quan hoặc trên các tập dữ liệu khác. Nói cách khác, thay vì phải xây dựng mô hình từ con số không, phương pháp này sử dụng các mô hình đã được huấn luyện trên lượng dữ liệu lớn, kế thừa và điều chỉnh kiến thức có sẵn để phù hợp với bài toán hiện tại. Nhờ vậy, nó không chỉ tối ưu thời gian và nguồn lực mà còn đem lại hiệu quả cao, đặc biệt trong trường hợp dữ liệu huấn luyện bị hạn chế.

Trong các bài toán thị giác máy tính, việc huấn luyện một mô hình CNN từ đầu thường đòi hỏi lượng dữ liệu lớn và thời gian huấn luyện dài. Tuy nhiên, trong các bài toán chuyên biệt như phát hiện ảnh bị chỉnh sửa, dữ liệu thường hạn chế và không đa dạng. Điều này làm cho việc huấn luyện từ đầu trở nên khó khăn và dễ dẫn đến hiện tượng overfitting. Học chuyển giao được xem là giải pháp hiệu quả trong trường hợp này, khi cho phép mô hình kế thừa các đặc trưng đã học từ dữ liệu nguồn và áp dụng cho bài toán mới. Nhờ đó, mô hình có thể đạt hiệu suất cao hơn với lượng dữ liệu ít hơn.

2.8.2. Pretrained Model

Pretrained model là các mô hình đã được huấn luyện trước trên một tập dữ liệu lớn và đa dạng, từ đó học được các đặc trưng tổng quát của dữ liệu đầu vào. Các mô hình này có thể được tái sử dụng cho các bài toán mới mà không cần huấn luyện lại từ đầu.

Trong quá trình huấn luyện, các mô hình học được các đặc trưng theo cấp bậc. Như đã nêu trước đó, các lớp đầu của mạng thường học các đặc trưng mức thấp như cạnh, góc và sự thay đổi cường độ sáng. Các lớp sâu hơn học các đặc trưng phức tạp hơn như kết cấu và cấu trúc hình học. Những đặc trưng này mang tính tổng quát và có thể áp dụng cho nhiều bài toán khác nhau. Chính nhờ khả năng học đặc trưng tổng quát này mà các mô hình pretrained có thể được sử dụng lại trong các bài toán khác mà không cần xây dựng lại toàn bộ mô hình từ đầu. Điều này đặc biệt hữu ích trong các trường hợp dữ liệu huấn luyện hạn chế hoặc bài toán có tính đặc thù cao.

Một điểm quan trọng là các đặc trưng cơ bản như cạnh, kết cấu và sự thay đổi cường độ sáng vẫn được bảo toàn ngay cả khi dữ liệu đầu vào được biến đổi, chẳng hạn như trong ảnh sao khi đã qua quá trình xử lí ELA. Do đó, các mô hình pretrained vẫn có khả năng trích xuất các đặc trưng hữu ích từ ảnh ELA, phục vụ cho bài toán phát hiện ảnh giả mạo.

2.8.3. Phương pháp Học chuyển giao

Trích xuất đặc trưng (Feature Extraction): Trong nghiên cứu này, các mô hình Pretrained được sử dụng như một bộ trích xuất đặc trưng. Các lớp ban đầu của mô hình được giữ nguyên (freeze) vì chúng đã học được các đặc trưng chung có thể áp dụng cho nhiều bài toán. Sau đó, các lớp mới được thêm vào phía sau để thực hiện

nhiệm vụ phân loại cụ thể. Chỉ các lớp này được huấn luyện trên dữ liệu mới, trong khi các lớp trước đó không thay đổi.

Tinh chỉnh (Fine-tuning): Quá trình này sẽ tiếp tục huấn luyện mô hình Pretrained trên dữ liệu mới bằng cách cập nhật một phần trọng số của mô hình. Thông thường, các lớp cuối của mạng sẽ được mở khóa (Unfreeze) để học các đặc trưng phù hợp hơn với bài toán mục tiêu. Trong quá trình tinh chỉnh, tốc độ học thường được đặt nhỏ để mô hình học kĩ các đặc trưng cũng như tránh làm mất đi các kiến thức đã học trước đó. Phương pháp này giúp mô hình thích nghi tốt hơn với dữ liệu mới và có thể đạt độ chính xác cao hơn.

2.8.4. Quy trình cơ bản trong Học chuyển giao

Quy trình áp dụng Học chuyển giao vào mô hình học máy để thực hiện một nhiệm vụ mới thường bao gồm bốn bước chính như sau:

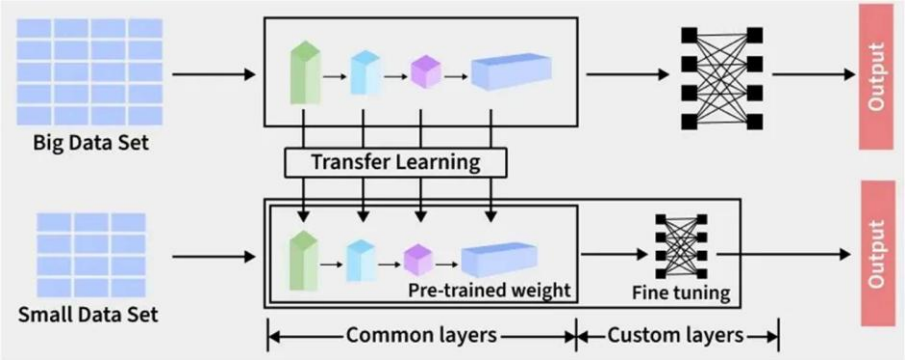
Bước 1: Chọn mô hình Pretrained: Khi bắt đầu một dự án Học chuyển giao, việc đầu tiên và quan trọng nhất là chọn một mô hình Pretrained phù hợp. Mô hình Pretrained là một mô hình đã được huấn luyện trên một tập dữ liệu lớn và có kiến trúc phức tạp, thường được xây dựng bởi các nhà nghiên cứu hoặc các công ty công nghệ lớn. Việc lựa chọn mô hình Pretrained phụ thuộc vào nhiều yếu tố, bao gồm:

- Kiến trúc mô hình: Chọn mô hình có kiến trúc phù hợp với loại dữ liệu.
- Tập dữ liệu huấn luyện: Tập dữ liệu đã được dùng để huấn luyện cho mô hình.
- Độ phức tạp: Mô hình càng phức tạp thì càng cần nhiều tài nguyên tính toán.

Bước 2: Đóng băng các lớp (Freeze Layer): Sau khi chọn được mô hình Pretrained, bước tiếp theo là đóng băng các lớp. Các lớp đầu tiên của mô hình Pretrained thường học được những đặc trưng chung như các cạnh, góc, texture trong hình ảnh. Các đặc trưng này có thể tái sử dụng được cho nhiều bài toán khác nhau. Bằng cách đóng băng các lớp này, chúng ta giữ nguyên kiến thức đã học được và tập trung vào việc huấn luyện các lớp mới để thực hiện nhiệm vụ cụ thể của mình.

Bước 3: Thêm các lớp mới: Để thực hiện nhiệm vụ mới, thêm các lớp mới được thêm vào cuối mô hình Pretrained. Các lớp này sẽ học các đặc trưng cụ thể cho bài toán của chúng ta. Số lượng lớp mới và kiến trúc của các lớp này phụ thuộc vào độ phức tạp của bài toán.

Bước 4: Tinh chỉnh đặc trưng: Sau khi xây dựng các lớp phân loại mới, mô hình được huấn luyện lại trên tập dữ liệu của bài toán. Trong quá trình này, chỉ các lớp mới và một số lớp cuối của mô hình được cập nhật trọng số, trong khi các lớp còn lại vẫn được giữ nguyên. Tốc độ học thường được thiết lập ở mức nhỏ nhằm đảm bảo việc điều chỉnh mô hình diễn ra ổn định và không làm ảnh hưởng đến các đặc trưng đã học trước đó.



Hình 18: Minh họa quy trình Học chuyển giao cơ bản (nguồn: geeksforgeeks.org)

Quy trình này cho phép tận dụng hiệu quả các đặc trưng đã học, đồng thời điều chỉnh mô hình để phù hợp với bài toán mới.

2.8.5. Ưu điểm và hạn chế của Học chuyển giao

* Ưu điểm của học chuyên giao

Tiết kiệm chi phí và thời gian: Học chuyển giao cho phép tái sử dụng các mô hình đã được huấn luyện, giảm thiểu đáng kể thời gian huấn luyện và khối lượng tài nguyên cần thiết. Bằng cách tận dụng những đặc trưng sẵn có, số lần huấn luyện để đạt được kết quả mong muốn cũng giảm, giúp đơn giản hóa và tăng tốc quy trình.

Hữu ích với lượng dữ liệu nhỏ: Trong trường hợp gặp khó khăn khi thu thập dữ liệu lớn, Học chuyển giao trở thành giải pháp lý tưởng. Phương pháp này giảm đáng kể nhu cầu về dữ liệu huấn luyện.

Cải thiện khả năng tổng quát hóa: Việc huấn luyện lại mô hình với dữ liệu mới cho phép nó tiếp thu từ nhiều tập dữ liệu khác nhau, nâng cao năng lực xử lý các loại dữ liệu đa dạng. Điều này giúp giảm nguy cơ overfitting và tăng khả năng áp dụng vào thực tế.

Tăng độ chính xác và tốc độ hội tụ: Học chuyển giao cung cấp một điểm khởi đầu với độ chính xác cao hơn, tốc độ cải thiện nhanh hơn và mức hiệu suất tối đa tốt hơn. Quá trình này đòi hỏi ít lần huấn luyện hơn so với việc xây dựng mô hình từ đầu.

* Hạn chế của học chuyển giao

Nguy cơ chuyển giao tiêu cực: Chuyển giao tiêu cực có thể xảy ra nếu bài toán gốc và bài toán mới không liên quan nhiều đến nhau. Điều này có nghĩa là mô hình có thể không áp dụng hiệu quả những gì đã học từ bài toán trước vào bài toán hiện tại. Kết quả là, thay vì cải thiện hiệu suất, mô hình có thể hoạt động kém hơn, làm mất đi lợi ích của Học chuyển giao.

Giới hạn về miền dữ liệu: Transfer Learning hoạt động tốt nhất khi dữ liệu của bài toán cũ và bài toán mới có sự tương đồng về nội dung hoặc đặc điểm (còn gọi là miền dữ liệu). Nếu dữ liệu giữa hai bài toán quá khác biệt, các kiến thức hoặc đặc trưng mà mô hình gốc đã học được sẽ không còn phù hợp để áp dụng vào bài toán mới. Điều này có thể làm giảm hiệu quả của mô hình và khiến việc chuyển giao trở nên không còn hữu ích.

Phụ thuộc vào chất lượng mô hình ban đầu: Hiệu quả của việc Học chuyển giao phụ thuộc lớn vào mô hình đã được huấn luyện trước. Nếu mô hình ban đầu không đủ mạnh hoặc dữ liệu huấn luyện ban đầu không đủ phong phú, việc chuyển giao kiến thức sẽ bị hạn chế.

2.8.6. Ứng dụng trong nghiên cứu

Trong nghiên cứu này, Học chuyển giao được áp dụng nhằm tận dụng các mô hình CNN đã được huấn luyện trước để phục vụ cho bài toán phát hiện ảnh giả mạo. Các mô hình như VGG19, ResNet50, EfficientNet-B0 và MobileNetV2 được sử dụng để trích xuất đặc trưng từ ảnh sai khác chất lượng nén. Các mô hình này đóng vai trò như các bộ trích xuất đặc trưng, giúp chuyển đổi ảnh đầu vào thành các biểu diễn đặc trưng có ý nghĩa.

Phương pháp Trích xuất đặc trưng được sử dụng làm cách tiếp cận chính, trong đó các lớp trích xuất đặc trưng được giữ nguyên và chỉ huấn luyện các lớp phân loại phía sau. Ngoài ra, quá trình Tinh chỉnh cũng được áp dụng đối với một số lớp cuối của mô hình nhằm nâng cao khả năng thích nghi với đặc trưng của dữ liệu đầu vào. Việc kết hợp giữa Học chuyển giao và Ảnh sai khác chất lượng nén giúp mô hình tập trung vào các dấu vết nén và sự không nhất quán trong ảnh, từ đó nâng cao hiệu quả phát hiện ảnh giả mạo.

2.9. Các mô hình Học chuyển giao

Trong nghiên cứu này, nhiều kiến trúc Mạng nơ-ron tích chập khác nhau được sử dụng nhằm đánh giá khả năng trích xuất đặc trưng và hiệu quả phân loại trong bài toán phát hiện ảnh bị chỉnh sửa. Ngoài một mô hình CNN tự thiết kế, tôi còn chọn thêm các mô hinh Pretrained bao gồm: VGG19, ResNet50, EfficientNet B0, MobileNetV2.

2.9.1. VGG19

* Khái niệm:

VGG19 là một kiến trúc Mạng nơ-ron tích chập sâu được thiết kế nhằm tăng khả năng học đặc trưng của mô hình thông qua việc gia tăng độ sâu của mạng. Mô hình thuộc họ VGG, được xây dựng với mục tiêu cải thiện độ chính xác trong các bài toán thị giác máy tính bằng cách sử dụng các lớp tích chập nhỏ và đồng nhất.

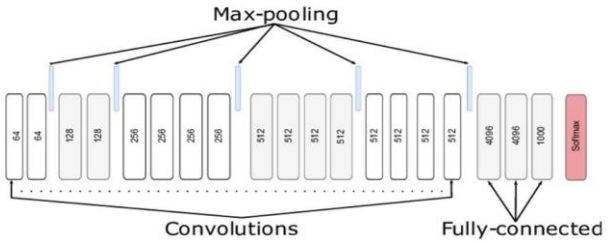
* Kiến trúc dạng khối (Block Structure):

VGG19 được tổ chức thành 5 khối tích chập chính. Mỗi khối gồm nhiều lớp Tích chập liên tiếp, sau đó là một lớp Gộp. Số lượng filter tăng dần qua các khối, giúp mô hình học từ đặc trưng đơn giản đến phức tạp. Thông thường, phần này gồm nhiều lớp Dense với số lượng nơ-ron lớn, giúp mô hình đưa ra quyết định cuối cùng.

* Kiến trúc:

Theo lý thuyết, kiến trúc của VGG19 được xây dựng dựa trên các thành phần chính sau:

- Lớp tích chập: VGG19 sử dụng các lớp tích chập với kích thước kernel nhỏ (3×3), stride = 1 và padding để giữ nguyên kích thước ảnh đầu vào. Các lớp tích chập này được xếp chồng liên tiếp thành từng khối, giúp tăng khả năng học đặc trưng. Việc sử dụng nhiều lớp tích chập nhỏ thay vì một lớp lớn giúp tăng độ phi tuyến của mô hình, giảm số lượng tham số và học được đặc trưng phức tạp hơn.
- Lớp gộp: Sau mỗi khối tích chập, VGG19 sử dụng lớp gộp Max Pooling với kích thước 2 × 2 và $stride$ = 2 để giảm kích thước không gian của đặc trưng. Quá trình này giúp giảm số chiều của dữ dữ liệu, giảm chi phí tính toán và Giữ lại các đặc trưng quan trọng nhất.
- Lớp kết nối đầy đủ: Đầu ra của lớp tích chập cuối cùng đang ở dạng các ma trận đặc trưng sẽ được đưa qua quá trình làm phẳng (Flatten) để chuyển đổi thành các vector 1 chiều (1D Vector). Các lớp kết nối đầy đủ sẽ tiếp nhận các vector đặc trưng trừu tượng này và truyền chúng qua các mạng nơ-ron. Quá trình tính toán tại đây sẽ đưa ra kết quả cuối cùng là các giá trị dự đoán để phân loại đối tượng vào từng nhãn tương ứng.



Hình 19: Kiến trúc VGG19 (Kamal et al. 2023)

* Ưu điểm

Bằng cách gia tăng độ sâu của mạng, VGG19 có nhiều ưu điểm nổi bật trong các bài toán xử lý ảnh. Mô hình có cấu trúc đơn giản, dễ hiểu, kiến trúc đồng nhất giúp cho việc triển khai và điều chỉnh trở nên dễ dàng hơn. Nhờ độ sâu lớn và việc sử dụng nhiều lớp tích chập nhỏ, mô hình có thể học được các đặc trưng tinh vi, phức tạp. Ngoài ra, các đặc trưng được học có tính tổng quát, phù hợp để sửa dụng trong Học chuyển giao.

2.9.2. ResNet50

* Khái niệm

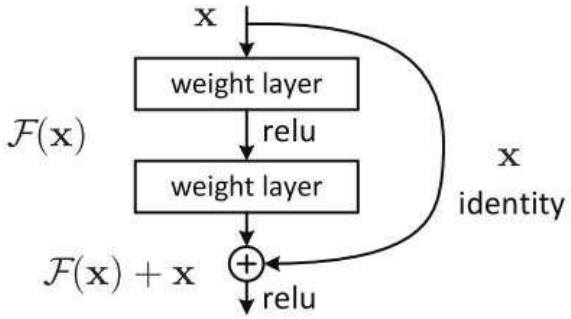
ResNet50 là một kiến trúc Mạng nơ-ron tích chập sâu thuộc họ Residual Network, được thiết kế nhằm giải quyết vấn đề triệt tiêu đạo hàm (vanishing gradient) khi độ sâu của mạng tăng lên. Khi mạng càng sâu, việc huấn luyện trở nên khó khăn do hiện tượng mất mát đạo hàm, dẫn đến mô hình không học được hiệu quả. Để khắc phục vấn đề này, ResNet50 giới thiệu cơ chế kết nối tắt (skip connection), cho phép thông tin được truyền trực tiếp từ các lớp trước đến các lớp sau. Nhờ đó, mô hình có thể huấn luyện hiệu quả với số lượng lớp lớn mà không bị suy giảm hiệu năng.

* Kiến trúc

- Cơ chế kết nối thặng dư (Residual Block): Thành phần cốt lõi của ResNet50 là các khối dư (Residual Blocks). Trong mỗi khối, đầu vào không chỉ được đưa qua các lớp tích chập mà còn được cộng trực tiếp với đầu ra của khối. Cơ chế này giúp mô hình học phần dư của đặc trưng thay vì học toàn bộ ánh xạ, từ đó giúp việc tối ưu trở nên dễ dàng hơn.
- Kiến trúc Bottleneck: ResNet50 sử dụng cấu trúc bottleneck trong mỗi khối dư, bao gồm ba lớp tích chập: o Lớp 1×1: giảm số chiều. o Lớp 3×3: trích xuất đặc trưng. o Lớp 1×1: khôi phục lại số chiều ban đầu.

Cấu trúc này giúp giảm số lượng tham số và chi phí tính toán, đồng thời vẫn đảm bảo khả năng học đặc trưng hiệu quả. Nhờ đó, ResNet50 có thể đạt được độ sâu lớn mà không làm tăng quá nhiều chi phí tính toán.

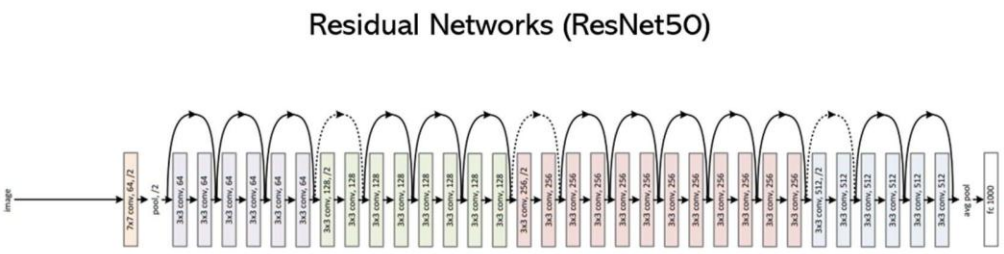
- Kết nối tắt (Shortcut Connection): Kết nối tắt là thành phần quan trọng nhất trong ResNet50, cho phép truyền trực tiếp đầu vào của một khối đến đầu ra của khối đó mà không đi qua các lớp tích chập trung gian. Cơ chế này giúp duy trì thông tin gốc xuyên suốt các tầng sâu, hỗ trợ lan truyền gradient hiệu quả trong quá trình huấn luyện, giảm thiểu hiện tượng triệt tiêu đạo hàm.



Hình 20: Minh họa Residual block (nguồn:viblo.asia)

Nhìn vào thông tin được cung cấp trong Hình 18, công thức toán học cốt lõi của các khối thặng dư được biểu diễn là $H(x) = f(x) + x$. Trong đó, x là dữ liệu đầu vào, $f(x)$ là hàm ánh xạ được học thông qua các weight layers. Hình minh họa mô tả cấu trúc cơ chế Kết nối tắt đặc trưng của mạng ResNet, nơi đầu vào x được truyền thẳng qua một nhánh phụ (identity) để cộng trực tiếp vào đầu ra của nhánh chính sau khi đã đi qua các lớp xử lý và hàm kích hoạt ReLU. Cơ chế này cho phép mạng nơ-ron truyền tín hiệu hiệu quả hơn ở các tầng rất sâu, giúp giải quyết hiện hiện tượng triệt tiêu đạo hàm bằng cách buộc các lớp trọng số chỉ cần tập trung học phần dư còn thiếu thay vì phải học lại toàn bộ ánh xạ mục tiêu từ đầu.

- Cấu trúc tổng thể: ResNet50 bao gồm 50 lớp, được tổ chức thành nhiều residual blocks nối tiếp nhau. Mạng bắt đầu bằng các lớp tích chập ban đầu, sau đó là các residual blocks với số lượng filter tăng dần. Các lớp cuối cùng bao gồm lớp pooling và lớp kết nối đầy đủ để thực hiện phân loại.



Hình 21: Minh học cấu trúc tổng thể của ResNet50 (nguồn: jananisbabu.github.io)

* Ưu điểm

ResNet50 có nhiều ưu điểm nổi bật so với các kiến trúc CNN truyền thống. Nhờ việc sử dụng cơ chế Cơ chế kết nối tắt, mô hình có khả năng giảm thiểu hiện tượng triệt tiêu đạo hàm, giúp quá trình huấn luyện các mạng sâu trở nên ổn định và hiệu quả hơn, cho phép xây dựng các mạng có độ sâu lớn mà không làm suy giảm hiệu năng. Bên cạnh đó, cấu trúc Bottleneck giúp giảm số lượng tham số và chi phí tính toán trong khi vẫn đảm bảo khả năng trích xuất đặc trưng mạnh mẽ. Nhờ những đặc điểm này, ResNet50 có khả năng học các đặc trưng phức tạp và đạt hiệu quả cao trong nhiều bài toán xử lý ảnh.

2.9.3. MobileNetV2

* Khái niệm

Kiến trúc MobileNetV2 là một Mạng nơ-ron tích chập được thiết kế đặc biệt cho các tác vụ học sâu nhẹ (Lightweight) và hiệu quả cao, cực kỳ phù hợp để triển khai trên các thiết bị di động và thiết bị nhúng có tài nguyên hạn chế. Mô hình được xây dựng với mục tiêu duy trì độ chính xác cao trong khi giảm thiểu chi phí tính toán so với các kiến trúc CNN truyền thống.

Điểm đặc trưng của MobileNetV2 là việc sử dụng các phép tích chập tách biệt (Depthwise Separable Convolution) kết hợp với cấu trúc Residual cải tiến, giúp mô hình đạt được hiệu suất tốt với kích thước nhỏ gọn.

* Kiến trúc

Theo nghiên cứu, lý thuyết nền tảng của MobileNetV2 xoay quanh 3 thành phần cốt lõi:

- Tích chập tách biệt theo chiều sâu:

MobileNetV2 phân tách phép toán tích chập truyền thống thành hai lớp hoạt động riêng biệt nhằm giảm thiểu chi phí tính toán:

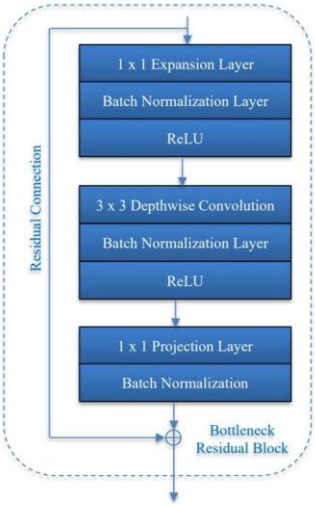
  - Tích chập theo chiều sâu (Depth-wise convolution): Thay vì áp dụng bộ lọc trên tất cả các kênh cùng lúc, nó áp dụng một bộ lọc duy nhất cho từng kênh đầu vào một cách độc lập. Điều này giúp giảm đáng kể khối lượng phép tính.

- Tích chập theo điểm (Point-wise convolution): Sử dụng các bộ lọc kích thước 1×1 để kết hợp các kênh đầu ra của bước trước đó lại với nhau, cho phép tạo ra sự tương tác thông tin chéo giữa các kênh.

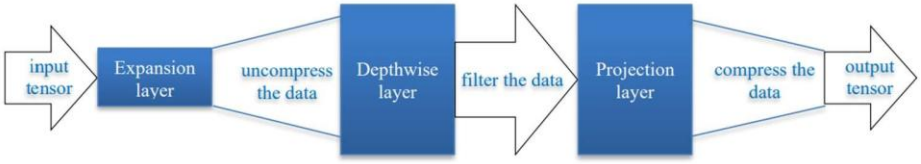
- Khối thặng dư đảo ngược: Thành phần này giúp mạng nắm bắt được các biểu diễn đặc trưng phong phú hơn nhưng lại tạo ra rất ít gánh nặng tính toán.
  Các khối này hoạt động theo một hệ thống gồm ba bước:
- Lớp mở rộng (Expansion Layer):

Hoạt động như một bộ giải nén. Nó chuyển đổi dữ liệu đầu vào (đang ở số chiều thấp) sang một không gian có số chiều cao hơn. Việc mở rộng này giúp lớp tích chập tiếp theo có đủ không gian để trích xuất các đặc điểm phức tạp.

- Lớp lọc (Depth-wise Layer): Thực hiện các hoạt động lọc dữ liệu trên không gian chiều đã được mở rộng.
- Lớp chiếu (Projection Layer): Hoạt động như một bộ nén. Sau khi trích xuất xong, lớp này nén dữ liệu từ không gian chiều cao về lại số chiều thấp ban đầu, đồng thời giữ lại toàn bộ những thông tin quan trọng nhất. Kết quả là dòng dữ liệu chảy giữa các khối thặng dư luôn được duy trì ở dạng nén (số chiều thấp) (Chathampally et al. 2024).



Hình 22: Khối thặng dư đảo ngược trên MobileNet V2 (Chathampally et al. 2024)



Hình 23: Hệ thống mở Rộng-Lọc-Nén trên MobileNetV2 (Chathampally et al. 2024)

- Nút thắt cổ chai tuyến tính (Linear Bottlenecks): Để giảm thiểu chi phí tính toán ở các bản đồ đặc trưng trung gian, MobileNetV2 triển khai cơ chế nút thắt cổ chai tuyến tính. Cụ thể, hệ thống áp dụng một phép tích chập 1×1 đi kèm với hàm kích hoạt tuyến tính (Linear Activation) sau bước tích chập theo

chiều sâu. Cơ chế này đảm bảo số lượng kênh duy trì ổn định xuyên suốt mạng nơ-ron, giúp tránh tình trạng quá tải tính toán.

* Ưu điểm

MobileNetV2 có nhiều ưu điểm nổi bật so với các kiến trúc CNN truyền thống. Trước hết, mô hình có số lượng tham số nhỏ và yêu cầu ít phép tính hơn, giúp giảm thời gian huấn luyện và suy luận. Việc sử dụng phép tích chập tách biệt giúp tăng hiệu quả tính toán mà vẫn giữ được khả năng học đặc trưng tốt. Cấu trúc Inverted Residual giúp cải thiện khả năng lan truyền thông tin và giảm hiện tượng mất mát thông tin trong quá trình học.

2.9.4. EfficientNet

* Khái niệm

EfficientNet được thiết kế nhằm tối ưu hóa hiệu suất của mô hình thông qua việc cân bằng giữa độ sâu, chiều rộng và độ phân giải đầu vào. Khác với các phương pháp truyền thống chỉ tăng một chiều của mạng, EfficientNet đề xuất một cách tiếp cận mới giúp mở rộng mô hình một cách đồng đều và hiệu quả hơn.

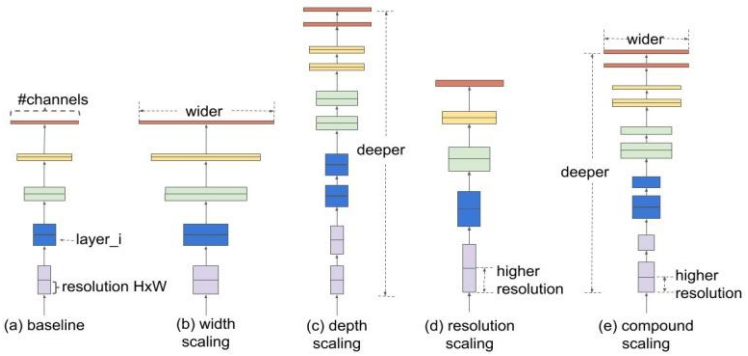
* Kiến trúc

- Phương pháp Compound Scaling:

Một trong những điểm nổi bật của EfficientNet là phương pháp mở sử dụng một hệ số chung duy nhất $\boldsymbol{\varphi}$ để phối hợp và thu phóng đồng đều cả chiều rộng (Width), độ sâu (Depth) và độ phân giải (Resolution) của mạng theo một tỷ lệ cân bằng và có nguyên tắc.

- Thu phóng thep độ sâu ($d = \alpha$): Tăng số lượng lớp của mạng nơ-ron. Việc tăng độ sâu giúp mạng học được các đặc trưng phức tạp hơn, tuy nhiên mạng quá sâu dễ dẫn đến hiện tượng triệt tiêu đạo hàm và khó huấn luyện.
- Thu phóng theo chiều rộng ($w = \beta$): Tăng số lượng filters trong mỗi lớp. Mạng rộng hơn có khả năng nắm bắt các đặc trưng chi tiết và mịn hơn, đồng thời quá trình huấn luyện cũng diễn ra dễ dàng hơn.
- Thu phóng theo độ phần giải ($r = \gamma$): Tăng kích thước hình ảnh đầu vào. Với độ phân giải cao, mạng có thể dễ dàng nhận diện các vật thể nhỏ và các chi tiết tinh vi trong ảnh.

Trong đó α, β, γ là các hằng số được xác định thông qua quá trình tìm kiếm (grid search), đảm bảo cân bằng giữa hiệu năng và chi phí tính toán.

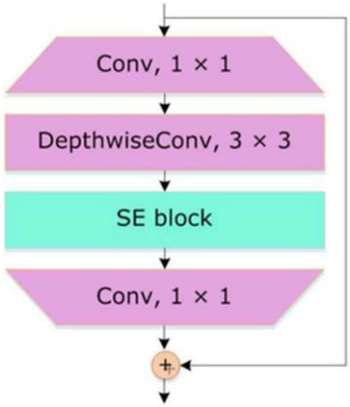


Hình 24: Minh họa các phương pháp Compound Scaling (source: viblo.asia)

- Khối MBConv (Mobile Inverted Bottleneck Convolution)

Đơn vị cơ bản của EfficientNet là khối MBConv, kế thừa từ MobileNetV2 kết hợp với cơ chế Squeeze-and-Excitation (SE). Cấu trúc này bao gồm ba giai đoạn chính:

- Giai đoạn mở rộng (Expansion): Sử dụng tích chập $1x1$ để tăng số lượng kênh, giúp tăng khả năng biểu diễn đặc trưng.
- Tích chập chuyên sâu (Depthwise Convolution): Thực hiện tích chập trên từng kênh riêng biệt ($3x3$ hoặc $5x5$), giúp giảm đáng kể chi phí tính toán so với tích chập truyền thống.
- Cơ chế Squeeze-and-Excitation: Tự động điều chỉnh trọng số của các kênh đặc trưng để tập trung vào các thông tin quan trọng nhất.
- Giai đoạn nén (Projection): Sử dụng tích chập $1x1$ để giảm số kênh về kích thước ban đầu trước khi thực hiện kết nối tắt (shortcut connection).

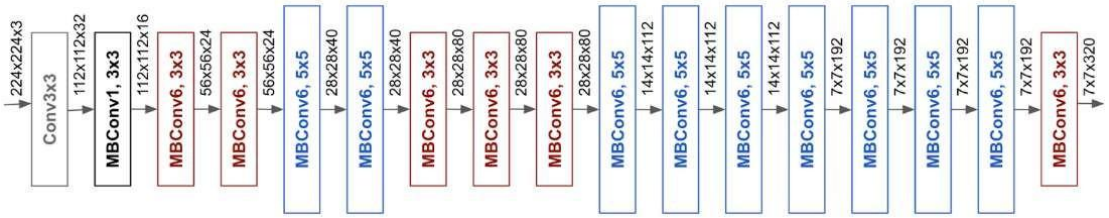


Hình 25: Minh họa cấu trúc của MBConv (researchgate.net)

- Cấu trúc tổng thể:

Kiến trúc tổng thể của EfficientNet-B0 được xây dựng theo sơ đồ phân tầng gồm 7 giai đoạn chính, sử dụng các khối biến thể MBConv làm đơn vị tính toán cốt lõi. Từ ảnh đầu vào kích thước $224x224x3$, dữ liệu được truyền qua một lớp khởi đầu (stem) và tuần tự xử lý bởi các khối có kích thước filter $3x3$ hoặc $5x5$ với các hệ số

mở rộng khác nhau. Trong suốt luồng xử lý này, độ phân giải không gian được nén dần từ $224x224x3$ xuống còn $7x7x320$ để trắc lọc thông tin, chiều sâu đặc trưng được mở rộng mạnh mẽ từ 32 lên 320 kênh ở lớp cuối cùng. Cách tiếp cận này giúp mạng nắm bắt được đa dạng các đặc trưng từ chi tiết nhỏ ở các tầng đầu đến các ngữ nghĩa toàn cục ở các tầng sâu, tạo ra sự cân bằng lý tưởng giữa hiệu suất nhận diện và tốc độ xử lý.



Hình 26: Kiến trúc cho mạng cơ sở EfficientNet-B0 (source: www.researchgate.net)

* Ưu điểm

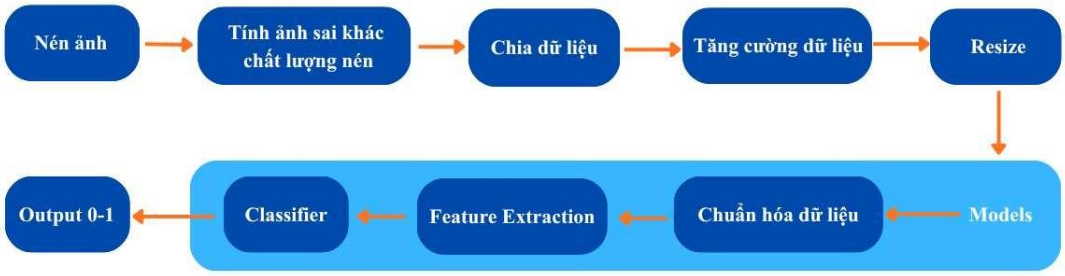
EfficientNet đạt độ chính xác cao trong khi sử dụng ít tham số hơn nhờ phương pháp Compound Scaling giúp tối ưu đồng thời độ sâu, chiều rộng và độ phân giải. Điều này giúp EfficientNet hiệu quả hơn về mặt tính toán so với các mô hình chỉ mở rộng theo một chiều.

CHƯƠNG 3: PHƯƠNG PHÁP THỰC HIỆN

3.1. Quy trình thực hiện:

Luận văn này được xây dựng theo hướng nghiên cứu thực nghiệm, sử dụng tập dữ liệu bao gồm các ảnh nguyên bản và ảnh đã bị chỉnh sửa với hai kỹ thuật phổ biến là Copy-Move và Splicing. Đây là bài toán Phân loại nhị phân bao gồm lớp Authentic và lớp Tampered. Trong nghiên cứu này, các mô hình học sâu được xây dựng nhằm khai thác các dấu vết nén JPEG để phục vụ cho bài toán phân loại và cũng đồng thời so sánh hiệu năng giữa các kiến trúc mô hình khác nhau nhằm trả lời các câu hỏi nghiên cứu đã đặt ra.

Khác với các hướng tiếp cận dựa trên đặc trưng ngữ nghĩa, nghiên cứu này tập trung vào việc khai thác các đặc trưng cấp thấp liên quan đến quá trình nén ảnh. Giả định chính là các vùng ảnh bị chỉnh sửa thường có sự không nhất quán về mức độ nén so với các vùng còn lại, từ đó tạo ra các dấu vết có thể được sử dụng để phát hiện giả mạo. Dựa trên giả định này, một quy trình xử lý thống nhất được đề xuất nhằm làm nổi bật các dấu vết nén và đưa chúng vào mô hình học sâu để học và phân biệt.



Hình 27: Quy trình thực hiện nghiên cứu

Quy trình tổng thể của hệ thống được thiết kế theo chuỗi các bước xử lý liên tiếp, bắt đầu từ ảnh đầu vào và kết thúc bằng kết quả phân lớp. Cụ thể, ảnh đầu vào trước tiên được nén JPEG nhằm tạo ra sự khác biệt về mức độ nén. Sau đó, ảnh sai khác chất lượng nén ($\boldsymbol{F_{diff}}$) được tính toán bằng cách lấy hiệu giữa ảnh gốc và ảnh sau khi nén, từ đó làm nổi bật các vùng có dấu hiệu bất thường. Dữ liệu tiếp tục được tăng cường thông qua các kỹ thuật Data Augmentation phù hợp nhằm cải thiện khả năng tổng quát hóa của mô hình. Sau bước này, dữ liệu được chuẩn hóa để đưa về cùng một thang giá trị để đảm bảo tính ổn định trong quá trình huấn luyện.

Các ảnh $\boldsymbol{F_{diff}}$ được sử dụng làm đầu vào cho mô hình CNN và các Pretrained models. Các trọng số của tập ImageNet sẽ được fine-tune trong quá trình học nhằm học các đặc trưng đặc thù liên quan đến dấu vết nén trong ảnh cho phù hợp với bài toán nghiên cứu. Cuối cùng, mô hình thực hiện phân lớp để đưa ra dự đoán ảnh thuộc lớp Authentic hay Tampered

3.2. Thu thập dữ liệu

3.2.1. Tập dữ liệu CASIA v2.0

Dữ liệu đóng vai trò nền tảng và có ảnh hưởng trực tiếp đến hiệu năng của mô hình. Đặc biệt đối với bài toán phát hiện ảnh bị chỉnh sửa, chất lượng, sự đa dạng và tính đại diện của dữ liệu là yếu tố quyết định khả năng học và tổng quát hóa của hệ thống. Do đó, bước đầu tiên trong quy trình nghiên cứu là thu thập và chuẩn bị một tập dữ liệu phù hợp để phục vụ cho quá trình huấn luyện và đánh giá mô hình.

Nghiên cứu này sử dụng tập dữ liệu CASIA v2.0, một bộ dữ liệu công khai và được sử dụng rộng rãi trong lĩnh vực phát hiện giả mạo ảnh số. Tập dữ liệu này bao gồm hai nhóm chính: ảnh nguyên bản (Authentic) và ảnh đã bị chỉnh sửa (Tampered). Các ảnh giả mạo trong CASIA v2.0 được tạo ra chủ yếu bằng hai kỹ thuật phổ biến là Copy-Move và Splicing, phù hợp với phạm vi bài toán được đề cập trong luận văn.

Về đặc điểm, tập dữ liệu CASIA v2.0 có sự đa dạng về nội dung và bối cảnh, bao gồm cảnh quan, con người, vật thể, kiến trúc. Bên cạnh đó, các ảnh có độ phân giải không đồng nhất và được thu thập từ nhiều nguồn khác nhau, dẫn đến sự khác biệt về chất lượng, ánh sáng và mức độ nhiễu. Chính sự đa dạng này giúp mô hình có cơ hội học được các đặc trưng tổng quát hơn, tuy nhiên cũng đặt ra thách thức trong việc xử lý và chuẩn hóa dữ liệu.

	Authentic	Forged		Total	Size	Format
		Copy-move	Splicing			
Number of images	7491	3274	1849	12614	320x240 900x600	BMP, JPEG, TIFF
Total	7491	5123		12614		

Hình 28: Tổng quan tập dữ liệu CASIA v2.0

3.2.2. Lọc dữ liệu

Ban đầu, toàn bộ các ảnh trong tập CASIA v2.0 được sử dụng làm nguồn dữ liệu đầu vào. Tuy nhiên, để đảm bảo chất lượng và tính nhất quán cho quá trình huấn luyện, dữ liệu cần phải được rà soát và chọn lọc trước khi đưa vào các bước xử lý tiếp theo. Một số ảnh trong tập dữ liệu có thể không phù hợp cho quá trình huấn luyện do các vấn đề như lỗi đọc file hoặc chất lượng ảnh quá thấp. Các ảnh này được loại bỏ để đảm bảo tính nhất quán của dữ liệu đầu vào.

3.3. Phân tích và tiền xử lý dữ liệu

Sau khi hoàn tất bước thu thập và tổ chức dữ liệu, giai đoạn tiếp theo là phân tích và tiền xử lý dữ liệu nhằm chuẩn bị đầu vào phù hợp cho mô hình học sâu. Đây là bước quan trọng, bởi dữ liệu đầu vào không chỉ cần đảm bảo tính nhất quán mà còn phải làm nổi bật các đặc trưng có ý nghĩa đối với bài toán phát hiện ảnh bị chỉnh sửa.

Qua quá trình kiểm tra và phân tích, có thể nhận thấy các ảnh trong tập dữ liệu có sự khác biệt đáng về kích thước, độ phân giải và chất lượng do được thu thập từ nhiều nguồn khác nhau. Đồng thời, các ảnh giả mạo thường trải qua nhiều lần chỉnh sửa và nén lại, dẫn đến sự không đồng nhất về mức độ nén giữa các vùng trong cùng một bức ảnh. Dựa trên đặc điểm này, nghiên cứu lựa chọn hướng tiếp cận khai thác các dấu vết nén JPEG thông qua việc xây dựng các bước tiền xử lý phù hợp.

3.3.1. Tính ảnh sai khác chất lượng nén:

Dựa trên giả định rằng vùng ảnh bị chỉnh sửa có dấu vết nén khác biệt, nghiên cứu này sử dụng kỹ thuật Error Level Analysis để tạo ảnh đầu vào cho mô hình. Trước tiên, các ảnh đầu vào được thực hiện tái nén bằng kỹ thuật nén JPEG với một mức chất lượng xác định. Quá trình này tạo ra một phiên bản ảnh mới với toàn bộ các vùng ảnh được nén lại theo cùng một mức độ.

Quy trình tính ảnh sai khác chất lượng nén diễn ra như sau:

1. Đọc ảnh vơi thư viện OpenCV.
2. Thực hiện nén ảnh với chất lượng Q = 95.
3. Giải nén ảnh thu được $\boldsymbol{F_{comp}}$.
4. Tính $\boldsymbol{F_{diff}}$:

$$F \quad = |F - F \quad |$$

Trong đó:

- F: Ảnh ban đầu.
- F : Ảnh sau khi nén.
- F : ảnh ELA hay ảnh sai khác chất lượng nén.

5. Lưu kết quả dưới định dạng JPEG.



Hình 29: Kết quả thu được sau bước tính ảnh sai khác chất lượng nén

Quan sát hình 27 có thể nhận thấy sự khác biệt rõ rệt giữa các vùng trong ảnh ELA. Các vùng không bị chỉnh sửa thường có mức sai khác rất thấp do quá trình tái nén không làm thay đổi đáng kể giá trị pixel nên các vùng này thường hiển thị với cường độ thấp và tương đối đồng đều trên ảnh ELA. Ngược lại, các vùng đã bị chỉnh sửa thường có lịch sử nén khác so với phần còn lại của ảnh. Khi thực hiện tái nén, các vùng này không tương thích hoàn toàn với mức nén mới, dẫn đến sự sai lệch lớn hơn về giá trị pixel. Điều này được thể hiện trên ảnh ELA dưới dạng các vùng có cường độ sáng cao hơn hoặc xuất hiện các điểm nhiễu rõ rệt so với nền xung quanh.

3.3.2. Phân chia tập dữ liệu

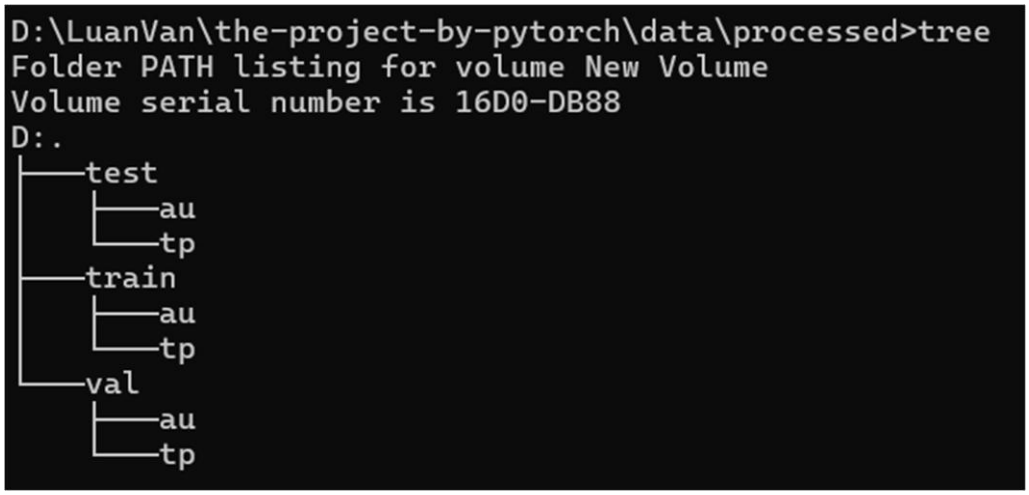
Sau khi lọc dữ liệu, tiến hành phân chia tập dữ liệu thành 3 tập riêng biệt với tỉ lệ tập Train 70% cho việc cập nhật trọng số trong quá trình huấn luyện, Validatiion 15% để theo dõi quá trình huấn luyện, điều chỉnh siêu tham số và chọn epoch tốt nhất, tập Test 15% dùng để đánh giá hiệu năng của mô hình sau khi hoàn thành huấn luyện.

Bảng 6: Bảng phân chia dữ liệu

	Train	Test	Validation
Tỉ lệ (%)	70	15	15
Số lượng ảnh	8829	1893	1892

Mỗi tập bao gồm 2 thư mục:

- Authentic : nhãn 0.
- Tampered : nhãn 1.



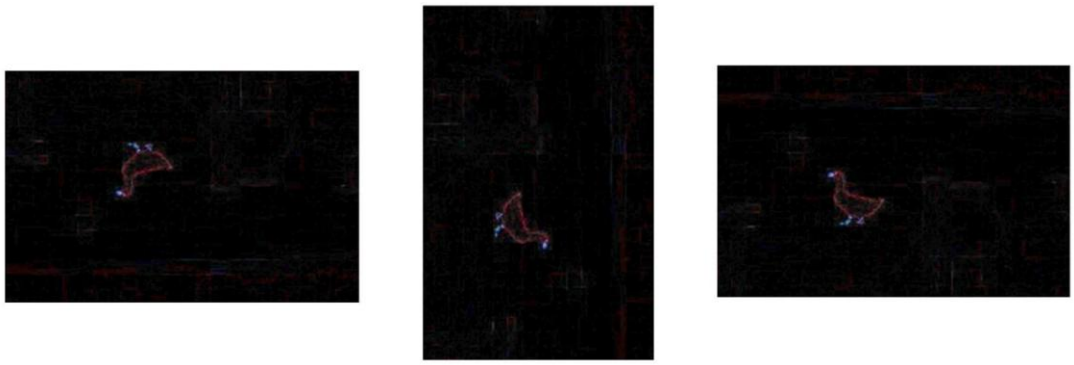
Hình 30: Cây thư mục của từng tập dữ liệu sau khi chia

3.3.3. Data Augmentation

Trong các bài toán học sâu, đặc biệt khi dữ liệu không quá lớn, tăng cường dữ liệu là một kỹ thuật quan trọng nhằm cải thiện khả năng tổng quát hóa của mô hình và giảm hiện tượng overfitting. Các phép biến đổi này giúp tạo ra nhiều biến thể khác nhau của cùng một ảnh mà không làm thay đổi bản chất nội dung. Tuy nhiên, do bài toán tập trung vào các đặc trưng cấp thấp liên quan đến dấu vết nén, việc lựa chọn phép biến đổi cần được kiểm soát cẩn thận. Cụ thể, các phép biến đổi mạnh như thay đổi màu sắc, làm mờ hoặc biến dạng hình học phức tạp không được sử dụng, vì có thể làm phá vỡ cấu trúc của các artifact trong ảnh. Việc sử dụng các phép biến đổi nhẹ giúp tăng số lượng dữ liệu mà vẫn giữ được thông tin quan trọng phục vụ cho việc phát hiện giả mạo.

Trong nghiên cứu này, các phép biến đổi hình học đơn giản được áp dụng trên tập huấn luyện, bao gồm:

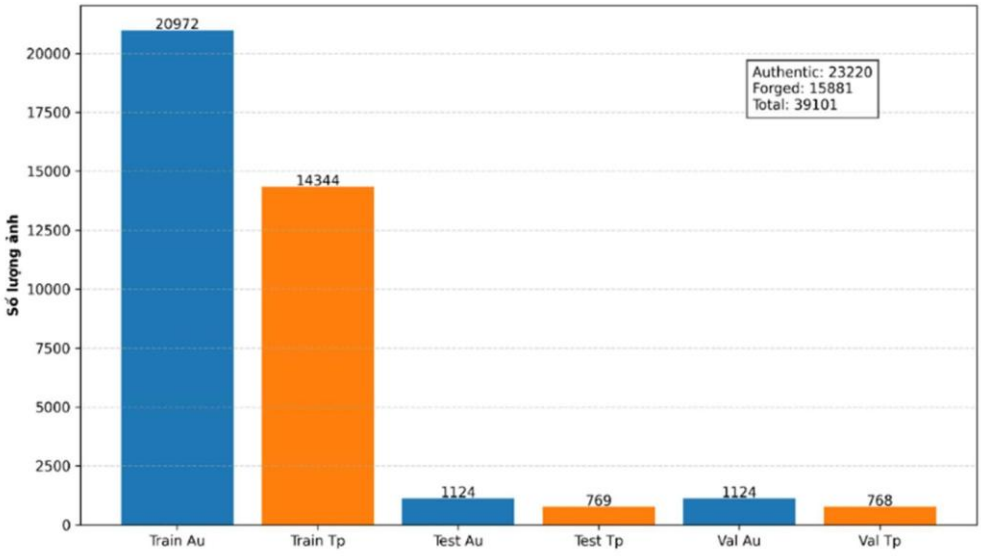
- Lật ngang.
- Xoay ảnh với góc 90° và 180°



Hình 31: Minh họa bước Data Augmentation

Theo hình 30, mỗi ảnh sinh ra thêm 3 ảnh biến đổi. Các phép biến đổi này chỉ làm thay đổi vị trí của các điểm ảnh, không làm thay đổi giá trị của chúng. Do đó, dấu vết nén được bảo toàn nguyên vẹn. Chỉ tăng cường trên tập Train để tránh hiện tượng rò rỉ dữ liệu (data leakage), đồng thời để mô hình học được đa dạng hơn các biến thể của kĩ thuật chỉnh sửa, tập Validation và Test không được tăng cường.

Trong nghiên cứu này, việc tăng cường dữ liệu được thực hiện trên ảnh $\boldsymbol{F_{diff}}$.



Hình 32: Biểu đồ phân bố dữ liệu sau khi tăng cường dữ liệu

Chú thích:

- Train Au: Số lượng ảnh thật trong tập huấn luyện.
- Train Tp: Số lượng ảnh chỉnh sửa trong tập huấn luyện.
- Test Au: Số lượng ảnh thật trong tập đánh giá.
- Test Tp: Số lượng ảnh chỉnh sửa trong tập đánh giá.
- Val Au: Số lượng ảnh thật trong tập kiểm thử.
- Val Tp: Số lượng ảnh chỉnh sửa trong tập kiểm thử.

3.3.4. Resize ảnh

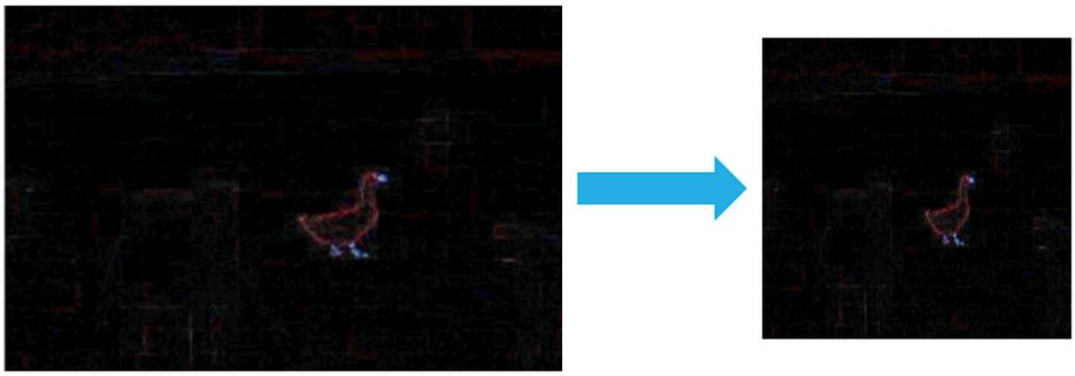
Các mô hình học sâu, đặc biệt là các kiến trúc CNN, yêu cầu dữ liệu đầu vào phải có kích thước cố định để đảm bảo tính nhất quán trong quá trình huấn luyện và suy luận. Do đó, trước khi đưa ảnh vào model và bắt đầu huấn luyện, tất cả các ảnh đều được resize về cùng một kích thước chuẩn.

Tuy nhiên, cần lưu ý rằng việc thay đổi kích thước ảnh có thể ảnh hưởng đến các đặc trưng cấp thấp, đặc biệt là các dấu vết nén JPEG vốn có cấu trúc theo khối (thường là 8×8 pixel). Nếu thực hiện resize không hợp lý, các đặc trưng này có thể bị biến dạng hoặc suy giảm, làm ảnh hưởng đến khả năng học của mô hình.

Vì vậy, trong quá trình thực hiện, việc lựa chọn kích thước ảnh được cân nhắc nhằm đảm bảo sự cân bằng giữa hai yếu tố:

- Giữ lại đủ thông tin cần thiết để nhận diện Dấu vết nén. - Đảm bảo hiệu quả tính toán trong quá trình huấn luyện.

Trong nghiên cứu này, tôi lựa chọn kích thước đầu vào là 224 × 224 điểm ảnh cho phù hợp với yêu cầu đầu vào của các Pretrained Models.



Hình 33: Minh họa resize ảnh đầu vào

3.4. Xây dựng mô hình

Trong nghiên cứu này, việc lựa chọn và thiết kế mô hình đóng vai trò then chốt trong việc xác định hiệu quả của hệ thống phát hiện hình ảnh bị chỉnh sửa. Thay vì chỉ sử dụng một kiến trúc duy nhất, đề tài triển khai song song hai hướng tiếp cận bao gồm: Xây dựng mô hình mạng nơ-ron tích chập tùy chỉnh (Custom CNN) và áp dụng các mô hình Transfer Learning. Cách tiếp cận này nhằm mục đích so sánh khả năng học đặc trưng giữa các mô hình được huấn luyện từ đầu với các mô hình đã được huấn luyện trước trên tập dữ liệu lớn.

Việc kết hợp hai hướng tiếp cận giúp đảm bảo tính toàn diện trong đánh giá, đồng thời cung cấp cái nhìn sâu s ắc về khả năng tổng quát hóa của từng loại kiến trúc khi áp dụng vào bài toán phát hiện giả mạo ảnh dựa trên đặc trưng ELA. Ngoài ra, việc sử dụng nhiều mô hình khác nhau còn giúp trả lời câu hỏi nghiên cứu về việc lựa chọn kiến trúc tối ưu trong bối cảnh dữ liệu cụ thể.

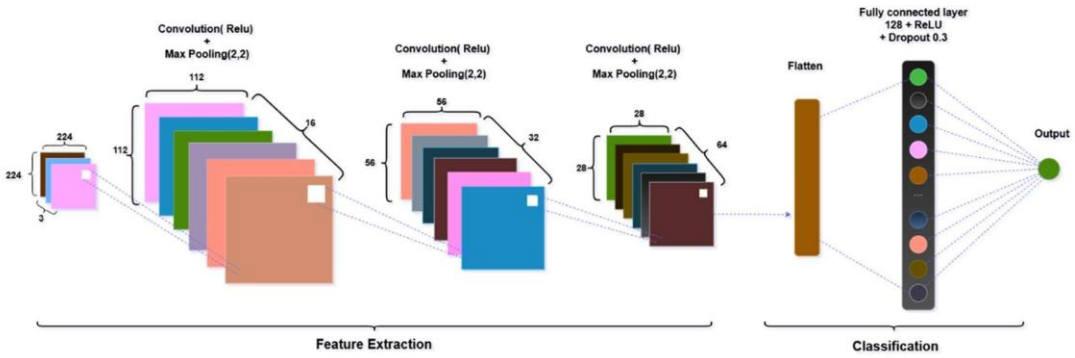
3.4.1. Mô hình Custom CNN

Mô hình Custom CNN được thiết kế nhằm mục tiêu kiểm chứng khả năng học đặc trưng trực tiếp từ dữ liệu đầu vào mà không phụ thuộc vào các trọng số đã được huấn luyện trước. Đây là một cách tiếp cận cơ bản nhưng quan trọng, giúp đánh giá mức độ phù hợp của dữ liệu và pipeline tiền xử lý đối với bài toán.

- Chuẩn hóa đầu vào: Mục đích của công việc việc này là đưa các giá trị đầu vào về một thang đo chung, giúp quá trình huấn luyện bằng thuật toán gradient descent đạt được sự hội tụ nhanh hơn và ổn định hơn. Đối với Custom CNN, tôi đưa giá trị pixel từ [0,255] về khoảng [0,1] bằng công thức:

$$I = \frac{I}{255}$$

Trong đó, I là ma trận pixel của ảnh đầu vào với giá trị ban đầu từ 0 đến 255, phép chia này được thực hiện trên cả 3 kênh màu RGB.



Hình 34: Kiến trúc mô hình Custom CNN

Mô hình được thiết kế với cấu trúc tuần tự gồm: feature extraction và classification

- Feature Extraction: Giai đoạn này gồm ba khối tích chập, mỗi khối bao gồm:
  - Lớp Input: Đầu vào của mô hình là tập ảnh Fdiff với 3 kênh màu RGB và các giá trị pixel đã được chuẩn hóa về [0,1].
  - Lớp Conv2D: với kích thước bộ lọc là 3×3, số lượng tăng dần qua các khối: 16, 32, 64. Việc tăng số kênh đặc trưng theo chiều sâu của mạng giúp mô hình học được các đặc trưng phức tạp hơn ở các tầng cao hơn. Hàm kích hoạt ReLU được sử dụng để đưa tính phi tuyến vào mô hình, đồng thời giảm thiểu hiện tượng vanishing gradient so với hàm sigmoid.
  - Lớp MaxPooling2D: sau mỗi khối Conv2D với kích thước cửa sổ 2×2, lớp này giúp giảm kích thước không gian của feature map (giảm một nửa chiều dài và chiều rộng), làm giảm số lượng tham số cần học, tăng khả năng chịu nhiễu. Sau ba lần MaxPooling, kích thước ảnh đầu vào 224×224 trở thành 28×28.
- Classification: Giai đoạn này bao gồm các lớp:

- Flatten: Layer này có nhiệm vụ làm phẳng đầu ra của giai đoạn Feature Extraction (một tensor 3D có kích thước 28×28×64) thành vector 1D. o Dense: Với 128 nơ-ron và hàm kích hoạt ReLU được sử dụng để thực hiện việc tổ hợp phi tuyến các đặc trưng.
- Dropout 0.3: Giúp làm giảm hiện tượng overfitting. Dropout ngẫu nhiên loại bỏ 30% số nút trong quá trình huấn luyện, buộc mạng học các đặc trưng dư thừa và có tính tổng quát hóa cao hơn.

Bảng 7: Bảng kiến của mô hình CNN tự thiết kế

Layer types	Parameters
Input layer	Input_shape = (224,224,3)
Conv2d	filters = 16, kernel_size = (3,3), padding = 'same' activation = 'relu'
MaxPooling2D	(2,2)
Conv2D	filters = 32, kernel_size = (3,3), padding = 'same'
MaxPooling2D	(2,2)
Conv2D	filters = 64, kernel_size = (3,3), padding = 'same'
MaxPooling2D	(2,2)
Flatten	-
Dense	128, activation = ‘relu’
Dropout	0.3
Dense	1, activation = sigmoid

3.4.2. Kiến trúc chung của các mô hình Học chuyển giao

Bên cạnh mô hình CNN tự xây dựng, nghiên cứu áp dụng phương pháp học chuyển giao nhằm tận dụng tri thức đã được học từ các tập dữ liệu lớn. Các mô hình Pretrained khác nhau được xem xét bao gồm: VGG19, ResNet50, MobileNetV2, và

EfficientNetV2 B0. Các mô hình này đã được huấn luyện trước trên ImageNet, một tập dữ liệu quy mô lớn với hàng triệu ảnh thuộc nhiều lớp khác nhau.

Trong nghiên cứu này, tất cả các mô hình Transfer Learning trong nghiên cứu được thiết kế theo một kiến trúc thống nhất nhằm đảm bảo tính nhất quán trong quá trình so sánh. Cụ thể, mỗi mô hình bao gồm hai thành phần chính:

- Mạng nền (Backbone): Là phần cốt lõi của mô hình, được khởi tạo bằng các trọng số pretrained từ ImageNet. Vai trò của mạng nền là trích xuất các đặc trưng từ ảnh đầu vào. Các đặc trưng này được biểu diễn dưới dạng tensor đa chiều, chứa thông tin về cấu trúc không gian và sự phân bố cường độ pixel. Việc sử dụng mạng nền đã được huấn luyện từ trước giúp mô hình không cần học lại các đặc trưng cơ bản, từ đó giảm đáng kể chi phí tính toán và thời gian huấn luyện.
- Classification Head: Là phần được thiết kế lại để phù hợp với bài toán phân loại nhị phân. Thông thường, phần này bao gồm: Lớp Global Average Pooling để giảm số chiều đặc trưng, một hoặc nhiều lớp Dense, Lớp Dropout (tùy chọn) và lớp đầu ra với hàm Sigmoid.

Các mô hình nêu trên đều có kiến trúc riêng, bao gồm một tập các lớp tích chập với các hàm kích hoạt và kết thúc bằng một tập các lớp kết nối đầy đủ có khả năng phân loại lên đến 1000 lớp ảnh theo chuẩn ImageNet. Vì vậy, kiến trúc của mỗi mô hình cần được sửa đổi để phù hợp với bài toán phân loại nhị phân của nghiên cứu – chỉ 2 lớp là Authentic hoặc Tampered.

Các lớp kết nối đầy đủ gốc của mỗi mô hình được thay thế bằng một bộ các lớp kết nối đầy đủ mới. Đầu vào có kích thước 224 × 224 × 3, được chuẩn hóa bằng hàm preprocess_input tương ứng của từng mạng nền. Cụ thể, bộ phân loại mới bao gồm:

- GlobalAveragePooling2D: giảm mỗi feature map thành một giá trị trung bình, chuyển tensor 3D thành vector 1D để đưa vào lớp tiếp theo.
- Dense: Kế đến là 2 lớp kết nối đầy đủ được thêm vào với hàm kích hoạt ReLU và có 1024, 256 nơ-ron tương ứng.
- Dropout: sau mỗi lớp Dense, một lớp Dropout với tỉ lệ ngẫu nhiên từ 0.2 đến 0.5 được thêm vào theo tùy mô hình để chống hiện tượng overfitting.
- Dense: Lớp kết nối đầy đủ cuối cùng với hàm kích hoạt sigmoid, đầy là hàm kích hoạt phổ biến trong bài toán phân loại nhị phân.

Bảng 8: Bảng thay đổi kiến trúc thống nhất của các mô hình Pretrained

Layer types	Parameters
GlobalAveragePooling2D	-
Dense	1024, activation = ReLU
Dropout	0.2 – 0.5
Dense	256, activation = ReLU

Dropout	0.2 – 0.5
Dense	1, activation = sigmoid

3.5. Chiến lược huấn luyện

Để tận dụng tối đa sức mạnh của các mô hình Pretrained đồng thời đảm bảo khả năng thích nghi với đặc thù của bài toán phát hiện ảnh giả mạo dựa trên dấu vết nén, nghiên cứu này áp dụng chiến lược huấn luyện hai giai đoạn. Mục tiêu của chiến lược này là giúp mô hình học được ánh xạ hiệu quả từ đặc trưng trích xuất bởi backbone sang nhãn phân loại (Authentic/Tampered), trước khi tiến hành tinh chỉnh các đặc trưng ở mức sâu hơn.

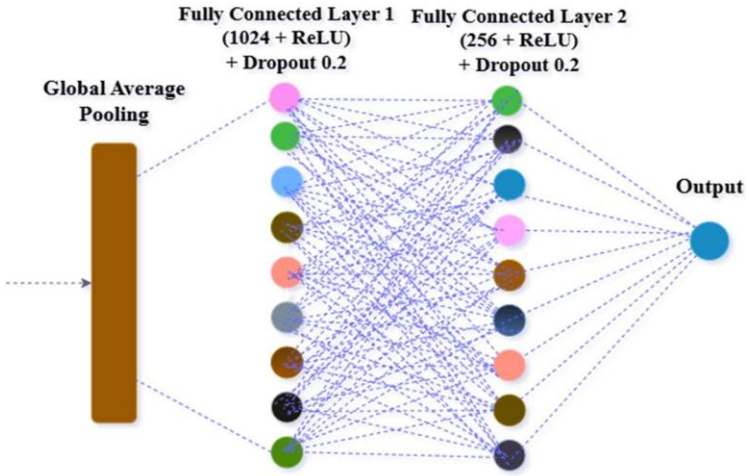
3.5.1. Cơ sở của chiến lược huấn luyện hai giai đoạn

Chiến lược huấn luyện hai giai đoạn được xây dựng dựa trên cơ chế lan truyền ngược sai số (backpropagation) trong mạng nơ-ron sâu.

Trong quá trình huấn luyện, sai số từ hàm mất mát được lan truyền ngược từ lớp đầu ra về các lớp phía trước để cập nhật trọng số. Nếu toàn bộ mô hình bao gồm cả backbone đã được huấn luyện trước được cập nhật ngay từ đầu, các gradient sinh ra từ lớp đầu ra có thể gây ra những thay đổi lớn đối với các trọng số của pretrained model. Điều này dẫn đến hiện tượng catastrophic forgetting (hiện tượng quên tri thức), trong đó các đặc trưng hữu ích học được từ tập dữ liệu lớn như ImageNet có thể bị phá vỡ. Bên cạnh đó, sự khác biệt giữa dữ liệu ImageNet và dữ liệu ảnh ELA khiến cho gradient ban đầu có thể mang tính nhiễu cao, làm cho quá trình cập nhật trọng số trở nên không ổn định, đặc biệt đối với các tầng sâu trong backbone.

Do đó, chiến lược huấn luyện được chia thành hai giai đoạn. Trong giai đoạn đầu, backbone được đóng băng để ngăn chặn gradient lan truyền vào các tầng này, chỉ cho phép cập nhật các lớp classification head. Khi classification head đã học được ánh xạ cơ bản giữa đặc trưng và nhãn, gradient trở nên ổn định và có ý nghĩa hơn. Lúc này, trong giai đoạn thứ hai, một phần backbone được mở khóa để tiếp tục huấn luyện, cho phép mô hình điều chỉnh các đặc trưng cao cấp phù hợp với dữ liệu cụ thể.

3.5.2. Giai đoạn 1: Huấn luyện Classification Head



Hình 35: Minh họa giai đoạn 1 - chỉ huấn luyện Classification Head

Trong giai đoạn đầu, toàn bộ các lớp của Backbone được giữ nguyên (freeze), sử dụng trực tiếp các trọng số pretrained để trích xuất đặc trưng từ ảnh đầu vào. Khi đó, các đặc trưng này được xem như một biểu diễn cố định của dữ liệu. Phần Classification head được gắn vào phía sau Backbone và được khởi tạo ngẫu nhiên. Classification head đóng vai trò như một bộ phân loại mới, có nhiệm vụ học ánh xạ từ không gian đặc trưng sang nhãn Authentic/Tampered.

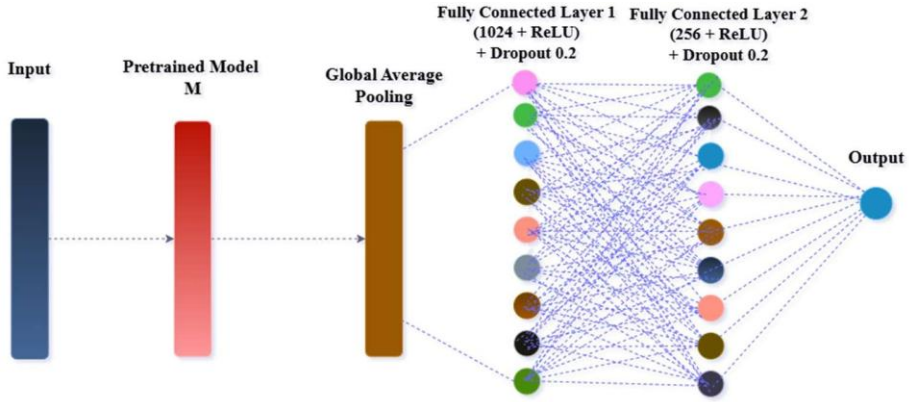
Do chỉ có một số lượng nhỏ tham số cần huấn luyện, quá trình học trong giai đoạn này diễn ra nhanh chóng và ổn định. Quan trọng hơn, việc đóng băng backbone giúp tránh việc các gradient không ổn định từ classification head làm ảnh hưởng đến các đặc trưng đã được học trước. Về mặt cơ chế, trong giai đoạn này, gradient chỉ được lan truyền và cập nhật trong các lớp của classification head, trong khi các lớp của backbone không bị thay đổi. Điều này giúp mô hình học được cách sử dụng hiệu quả các đặc trưng đã có mà không làm suy giảm chất lượng của chúng.

3.5.3. Giai đoạn 2: Tinh chỉnh một phần Mạng nền

Sau khi Classification Head đã học được ánh xạ cơ bản, mô hình chuyển sang giai đoạn fine-tuning. Trong giai đoạn này, một phần các lớp phía sau của Backbone được mở khóa (unfreeze) để tiếp tục huấn luyện vì các tầng này thường chứa các đặc trưng mang tính đặc thù cao, phù hợp để điều chỉnh theo dữ liệu mới. Trong khi đó, các tầng đầu vẫn được giữ nguyên nhằm bảo toàn các đặc trưng tổng quát như cạnh, kết cấu và hình dạng cơ bản.

Trong giai đoạn fine-tuning, gradient được lan truyền ngược không chỉ qua classification head mà còn qua các tầng backbone đã được mở khóa. Điều này cho phép mô hình điều chỉnh các đặc trưng ở mức cao sao cho phù hợp hơn với đặc trưng của ảnh ELA.

Để đảm bảo tính ổn định, learning rate trong giai đoạn này thường được giảm xuống so với giai đoạn đầu. Điều này giúp tránh việc cập nhật quá mạnh làm phá vỡ các trọng số đã được huấn luyện trước.



Hình 36: Minh họa giai đoạn 2 - huấn luyện Classification Head và một phần Backbone

3.5.4. Ưu điểm của việc huấn luyện 2 giai đoạn:

Chiến lược huấn luyện hai giai đoạn mang lại nhiều ưu điểm quan trọng trong việc tối ưu hiệu năng của các mô hình học chuyển giao.

Thứ nhất, việc đóng băng backbone trong giai đoạn đầu giúp bảo toàn các đặc trưng đã được học từ tập dữ liệu lớn như ImageNet, từ đó tránh hiện tượng catastrophic forgetting do các gradient không ổn định từ các lớp mới gây ra.

Thứ hai, khi Classification Head có thể học được ánh xạ cơ bản giữa đặc trưng và nhãn trong thời gian ngắn trước khi tiến hành tinh chỉnh toàn bộ hệ thống giúp mô hình hội tụ nhanh và ổn định hơn. Ngoài ra, việc chỉ cập nhật một phần nhỏ các tham số trong giai đoạn đầu còn giúp giảm đáng kể chi phí tính toán và thời gian huấn luyện. Khi chuyển sang giai đoạn fine-tuning, mô hình có thể điều chỉnh các đặc trưng cao cấp một cách có kiểm soát, từ đó cải thiện khả năng thích nghi với dữ liệu cụ thể.

Bảng 9: Bảng tóm tắt chiến lược huấn luyện các mô hình Pretrained

Model	Total Layers	Unfreeze Strategy
VGG19	22	block_5
EfficientNet B0	276	block5 block6 top_conv
MobileNet V2	160	block_13 - block_16 top_conv.
ResNet50	182	conv5_block3

3.6. Cấu hình huấn luyện

Việc điều chỉnh các tham số như optimizer, learning rate, loss function, callbacks, số epoch huấn luyện,... phù hợp là công viêc vô cùng quan trọng để tối ưu mô hình. Để đảm bảo sự công bằng và tính khách quan, tất cả các mô hình đều được huấn luyện với cấu trúc giống nhau nhất có thể. Tuy nhiên, giá trị các tham số này có thể chênh lệnh để tránh hiện tượng overfiting.

- Optimizer: Nghiên cứu này sử dụng bộ tối ưu Adam (Adaptive Moment Estimation).
- Learning rate: Tốc độ học khởi tạo được đặt là 1e-3 cho tất cả các mô hình. Ở giai đoạn hai của fine-tuning, khi mở khóa một phần backbone, cùng tốc độ học ban đầu được sử dụng là 1e-3,callback ReduceLROnPlateau được thêm vào để giảm tốc độ học nếu loss trên tập validation không cải thiện sau 2 epoch cho đến khi đạt ngưỡng tối thiểu 1e-7.
- Loss function: sử dụng binary crossentropy.
- Các callbacks được sử dụng:
  - Early Stopping: Dừng huấn luyện khi chỉ số val_loss không cải thiện sau 3 epochs. Ngoài ra, tham số restore_best_weights = True được dùng để đảm bảo mô hình được khôi phục về trạng thái có val_loss tốt nhất, tránh hiện tượng overfitting.
  - ReduceLROnPlateau: Tự động giảm learning rate khi val_loss ngừng giảm. Hệ số giảm 0.5 (learning rate nhân với 0.5), áp dụng khi sau 2 epoch không cải thiện.Mục đích là để tốc độ học chậm lại, mô hình học kĩ hơn, giúp quá trình hội tụ mượt mà hơn ở giai đoạn fine-tuning.
  - ModelCheckpoint: Lưu trọng số của mô hình vào file .keras ngay khi val_loss đạt giá trị thấp nhất. Đảm bảo giữ lại phiên bản tốt nhất của mô hình ngay cả khi các epoch sau đó bị overfitting.

Bảng 10: Bảng tóm tắt cấu hình huấn luyện

Tham số	Giá trị
Optimizer	Adam
Learning rate khởi tạo	1.00E-03
Loss function	Binary crossentropy
Epoch tối đa	50
Batch size	32
Early Stopping	patience = 3, monitor = val_loss, restore_best_weights = True
ReduceLROnPlateau	factor = 0.5, patience = 2

Trong nghiên cứu này, các mô hình học chuyển giao sử dụng chiến lược huấn luyện là đồng bộ hóa Giai đoạn khởi tạo và cá nhân hóa Giai đoạn tinh chỉnh một phần. Mọi mô hình đều bắt đầu Giai đoạn 1 với cùng một quy tắc: đóng băng toàn bộ mạng nền và chỉ huấn luyện lớp phân loại mới. Tuy nhiên, sự bứt phá về hiệu năng sẽ được quyết định ở Giai đoạn 2, nơi vị trí các lớp được phép mở khóa thay đổi hoàn toàn phụ thuộc vào kiến trúc đặc trưng của từng mạng.

3.7. Môi trường thực hiện:

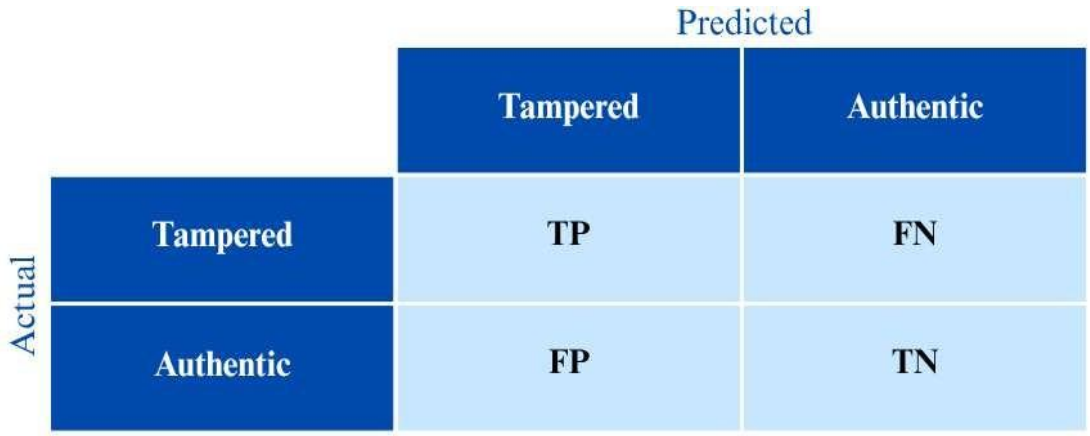
Tất cả các thí nghiệm được thực hiện trên nền tảng Kaggle Notebook với cấu hình như sau:

- GPU: NVIDIA Tesla P100 (16 GB VRAM) và 25 GB System RAM. Cấu hình phần cứng này đáp ứng tốt khả năng tính toán ma trận lớn mà không xảy ra hiện tượng tràn bộ nhớ.
- Framework: Các mô hình học sâu được xây dựng và tiến hành huấn luyện thông qua nền tảng TensorFlow 2.13 và Keras API.
- Ngôn ngữ lập trình: Python 3.10.
- Hệ điều hành: Linux – môi trường chuẩn của Kaggle.

3.8. Chỉ số đánh giá mô hình

Sau khi hoàn thành huấn luyện các mô hình Custom CNN, VGG16, MobileNet V2, ResNet50, EfficientNet B0, sử dụng tập Test đã được chia và cách li hoàn toàn với Train và Validation để đánh giá mô hình. Các chỉ số đánh giá này sẽ được dùng để so sánh hiệu năng của cách mô hình và lựa chọn mô hình có hiệu năng tốt nhất.

Trong nghiên cứu này, tôi chọn ngưỡng threshold 0.5 để phân chia hai lớp Positive và Negative.



Hình 37: Ma trận nhầm lẫn cho bài toán phân loại hình ảnh giả mạo

Chú thích Hình 37

- Lớp Dương tính (Positive): ảnh Tampered
- Lớp Âm tính (Negative): ảnh Authentic
- TN (True Negative): Số lượng ảnh là Authentic được mô hình dự đoán dự đoán là Authentic.
- TP(True Positive): Số lượng ảnh là Tampered được mô hình dự đoán dự đoán là Tampered.
- FP (False Positive): Số lượng ảnh Authentic nhưng bị dự đoán là Tampered.
- FN (Negative Positive): Số lượng ảnh Tampered nhưng bị dự đoán là Authentic.

3.8.1. Accuracy

Accuracy hay Độ chính xác là tỷ lệ các trường hợp được dự đoán đúng trên tổng số các trường hợp. Độ chính xác giúp đánh giá hiệu quả dự báo của mô hình trên một bộ dữ liệu. Độ chính xác càng cao thì mô hình của chúng ta càng chuẩn xác.Công thức tính:

$$Accuracy = \frac{TP + TN}{Total\ sample} \quad \frac{TP + TN}{P + N} =$$

Trong các chỉ số đánh giá mô hình phân loại thì Accuracy là chỉ số khá được ưa chuộng vì nó có công thức tường minh và dễ diễn giải ý nghĩa. Tuy nhiên, dù Accuracy là chỉ số quan trọng nhưng nó có thể không phản ảnh đúng hiệ suất của mô hình trong bài toán có tập dữ liệu bị mất cân bằng.

3.8.2. Precision

Precision là chỉ số thể hiện tính chính xác của dữ đoán trên lớp Positive, chỉ số này trả lời cho câu hỏi trong các trường hợp được dự báo là Dương tính thì có bao nhiêu trường hợp là đúng.

$$Precision = \frac{TP}{Total\ predicted\ positive} \quad \frac{TP}{TP + FP} =$$

Chỉ số này quan trọng trong bài toán mà việc dự đoán sai lớp Dương tính gây hậu quả nghiêm trọng.

3.8.3. Recall

Chỉ số này còn được gọi là Sensitivity hay True Positive Rate(TPR), thể hiện tỷ lệ các mẫu Positve thực sự mà mô hình đoán đúng trên tổng số mẫu Dương tính.

$$Recall = \frac{TP}{Total\ actual\ positive} \quad \frac{TP}{TP + FN} =$$

Đây là chỉ số quan trọng để đánh giá khả năng nhận diện đúng lớp Dương tính của mô hình. Cũng như Precision, Recall là chỉ số đặc biệt quan trọng trong các bài toán mà không nên bỏ sót các trường hợp Dương tính.

3.8.4. F1-Score

F1-Score là trung bình điều hòa giữa precision và recall. Do đó nó đại diện hơn trong việc đánh gía độ chính xác trên đồng thời precision và recall. Chỉ số này đặc biệt hữu ít trong bài toán bị mất cân bằng dữ liệu:

$$F = \frac{2\ x\ Precision\ x\ Recall}{Precision + Recall}$$

F1-Score là chỉ số quan trọng khi có sự đánh đổi giữa Precision và Recall. Trong những tình huống cần cân bằng giữa việc giảm False Positive (FP) và False Negative (FN), F1-Score cung cấp một cái nhìn toàn diện hơn so với chỉ sử dụng riêng Precision hay Recall.

3.8.5. AUC

ROC (Receiver Operating Characteristic) là đường biểu diễn khả năng phân loại của một mô hình phân loại tại các ngưỡng threshold. Đồ thị này được xây dựng dựa trên sự đánh đổi giữa hai đại lượng: True Positive Rate – TPR và False Positive Rate – FPR. Thay vì chỉ đánh giá ở một điểm cố định, đường ROC mô phỏng sự thay đổi của hai tỷ lệ này khi ta liên tục dịch chuyển ngưỡng phân loại threshold chạy dọc trong khoảng từ 0 đến 1.

- TPR (True Positive Rate): Hay còn gọi là recall hoặc sensitivity.

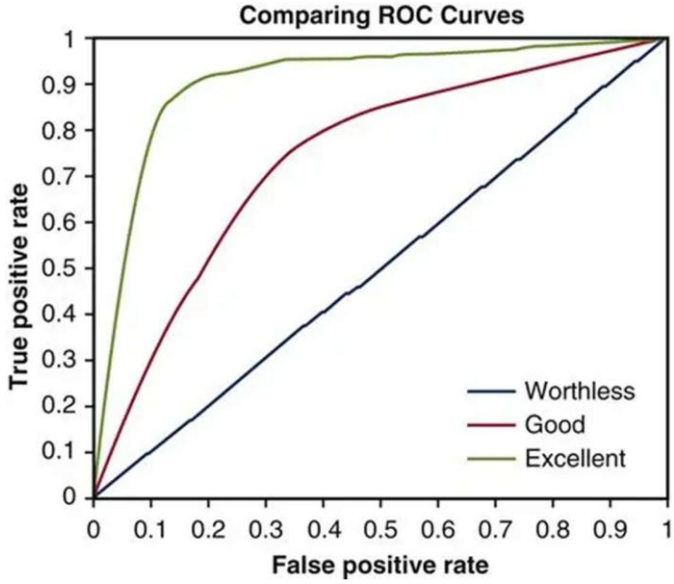
$$TPR = \frac{TP}{TP + FN}$$

- Specificity: Biểu diễn tỷ lệ phân loại chính xác các mẫu âm tính trên tất cả các mẫu âm tính, được tính theo công thức:

$$Specificity = = \frac{TN}{+ FP} TN$$

- FPR (False Positive Rate): Tỷ lệ dự báo sai các trường hợp thực tế là âm tính thành dương tính trên tổng số các trường hợp thực tế là âm tính. Được tính bằng công thức

$$FPR = 1 - Specificity = \frac{FP}{FP + TN}$$



Hình 38: Minh họa 3 loại đường ROC

AUC (Area Under the Curve) là chỉ số được tính toán dựa trên đường cong ROC nhằm đánh giá khả năng phân loại của mô hình. Biểu đồ trong Hình 38 thể hiện đường ROC cho 3 mô hình giả định, mỗi mô hinh có hiệu suất khác nhau. Trong đó:

- Trục X đại diện cho tỷ lệ dương tính giả FPR.
- Trục Y đại diện cho tỷ lệ dương tính thực TPR.
- Phần diện tích phía dưới đường ROC và trên trục hoành là AUC có giá trị nằm trong khoảng [0, 1].

Khi diện tích càng lớn thì đường ROC có xu hướng tiệm cận đường thẳng và khả năng phân loại của mô hình càng tốt. Khi đường ROC nằm sát với đường chéo đi qua hai điểm (0, 0) và (1, 1), lúc này mô hình sẽ tương đương với một phân loại ngẫu nhiên.

Trong nghiên cứu này, AUC được lựa chọn làm chỉ số đánh giá chính vì tập dữ liệu đầu vào CASIA v2.0 có sự mất cân bằng giữa các lớp (7491 ảnh nguyên bản so với 5123 ảnh bị chỉnh sửa). Trong khi các chỉ số như Accuracy dễ bị sai lệch do sự mất cân bằng này và phụ thuộc vào một ngưỡng phân loại duy nhất thì AUC đánh giá hiệu năng của mô hình trên mọi ngưỡng phân loại có thể có. Điều này giúp đánh giá khả năng phân tách đặc trưng của mô hình một cách toàn diện, khách quan và phản ánh đúng hiệu quả của bài toán.